

ĐẠI HỌC UEH

TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ THIẾT KẾ



KHOA CÔNG NGHỆ THÔNG TIN KINH DOANH

ĐỒ ÁN CUỐI KÌ

MÔN HỌC: BIỂU DIỄN TRỰC QUAN HÓA DỮ LIỆU

**ĐỀ TÀI: PHÂN TÍCH DỮ LIỆU NỘI DUNG ĐƯỢC ĐĂNG TẢI
TRÊN NỀN TẢNG NETFLIX**

GVHD: Ts. Nguyễn An Tế

Nhóm 3:

Lâm Vĩ Kiệt

31221020030

Vương Thùy Linh

31221026306

Quách Tuấn Khôi

31221021271

Lê Đình Anh Khoa

31221020853

Nguyễn Trần Thảo Khuyên

31221023315

Trang Tô Thiên Lộc

31221021005

Mã LHP: 24C1INF50908201

TP. Hồ Chí Minh, ngày 08 tháng 12 năm 2024

BẢNG PHÂN CÔNG

Nhiệm vụ	Thành viên	Mức độ hoàn thành
- Phụ trách chương 5.	Trang Tô Thiên Lộc	60%
- Phụ trách chương 2, 5, 6. - Phụ trách làm slide.	Nguyễn Trần Thảo Khuyên	100%
- Phụ trách chương 6, 7. - Phụ trách làm code.	Lâm Vĩ Kiệt	100%
- Phụ trách chương 5, 6. - Phụ trách làm slide.	Lê Đình Anh Khoa	100%
- Phụ trách chương 3, 6, 7. - Phụ trách làm code.	Quách Tuấn Khôi	100%
- Phụ trách các chương 1, 4 - Phụ trách làm code.	Vương Thùy Linh (nhóm trưởng)	100%

NỘI DUNG

CHƯƠNG I: TỔNG QUAN ĐỀ TÀI	10
1. Sơ lược đề tài.....	10
2. Mục tiêu nghiên cứu	10
3. Phương pháp nghiên cứu.....	10
4. Tài nguyên sử dụng	11
CHƯƠNG II: TỔNG QUAN BỘ DỮ LIỆU	12
1. Sơ lược về bộ dữ liệu.....	12
2. Mô tả thuộc tính của bộ dữ liệu.....	12
3. Mô tả tổng quan bộ dữ liệu ban đầu	13
3.1. Thông tin cơ bản.....	13
3.2. Kiểm tra dữ liệu.....	13
3.3. Trực quan hóa dữ liệu.....	14
CHƯƠNG III: ĐỊNH DẠNG VÀ Ý NGHĨA CỦA BỘ DỮ LIỆU	17
CHƯƠNG IV: TIỀN XỬ LÝ DỮ LIỆU	22
1. Thông tin cơ bản.....	22
2. Kiểm tra dữ liệu.....	22
3. Trực quan hóa dữ liệu.....	25
CHƯƠNG V: TRỰC QUAN HÓA DỮ LIỆU	27
1. Dòng thời gian (Times Series).....	27
1.1. Số lượng nội dung được thêm vào theo tháng và năm.....	27
1.2. Biểu đồ chấm theo năm phát hành và thời lượng phim	28
1.3. Biểu đồ chấm theo năm phát hành và số mùa của TV show.....	30
1.4. Số lượng phim và chương trình TV theo năm	33
2. Vị trí địa lý.....	36
2.1. Phân phối thời lượng của phim theo khu vực	36
2.2. Những quốc gia có nhiều nội dung nhất	37

2.3. Số lượng nội dung theo châu lục.....	38
2.4. Số lượng phim theo khu vực và thể loại	40
2.5. Đạo diễn với nhiều nội dung nhất theo khu vực	41
2.6. Đạo diễn sản xuất nhiều bộ phim nhất theo quốc gia	42
2.7. Diễn viên đóng nhiều bộ phim nhất theo quốc gia	44
2.8. Tỷ lệ của từng thể loại phim theo quốc gia	46
3. Phân phối theo tính chất và thể loại	47
3.1. Phân phối thể loại theo Phim và chương trình TV	47
3.2. Tỷ lệ phim theo đối tượng của từng quốc gia	48
3.3. Thể loại.....	51
3.4. Phân phối Châu lục, Thời lượng và Đối tượng Mục tiêu.....	52
3.5. Những chương trình TV có nhiều mùa nhất	53
CHƯƠNG VI: PHÂN CỤM DỮ LIỆU	55
1. Tiền xử lý dữ liệu cho phân cụm và xây dựng hệ thống gợi ý	55
2. Trích xuất đặc trưng văn bản với TF-IDF.....	57
2.1. Lý thuyết về TF-IDF	57
2.2. Thực nghiệm trích xuất đặc trưng với Python	58
3. Áp dụng PCA giảm chiều dữ liệu	59
3.1. Lý thuyết về PCA.....	59
3.2. Tiến hành thực nghiệm giảm chiều dữ liệu với PCA trên Python.	60
4. Phân cụm K-means	61
4.1. Học máy không giám sát.....	61
4.2. Thuật toán phân cụm K-means	61
4.3. Thực hiện thuật toán KMeans-Clustering trên Python	62
5. Phân tích kết quả sau khi phân cụm với KMeans.....	63
5.1. Tổng quan kết quả phân cụm	64
5.2. Phân tích cụm 0	67
5.3. Phân tích cụm 1	70

5.4. Phân tích cụm 2	73
5.5. Phân tích cụm 3	76
5.6. Phân tích cụm 4	79
5.7. Phân tích cụm 5	81
5.8. Phân tích cụm 6	84
CHƯƠNG VII: XÂY DỰNG RECOMMEND SYSTEM.	88
1. Khái niệm về Recommend System	88
2. Lý thuyết về Cosine Similarity	89
3. Triển khai Recommend System trên Python	89
TÀI LIỆU THAM KHẢO	94

DANH MỤC BẢNG BIỂU

Bảng 1: Mô tả ý nghĩa các cột dữ liệu ban đầu	13
Bảng 2: Định dạng và ý nghĩa của bộ dữ liệu	21

DANH MỤC HÌNH ẢNH

Hình 1: Số lượng hàng và cột của bộ dữ liệu ban đầu	13
Hình 2: Số giá trị bị thiếu trong mỗi cột	14
Hình 3: Các biểu đồ phân phối cho dữ liệu phân loại của dữ liệu gốc.....	15
Hình 4: Biểu đồ phân phối nội dung theo năm phát hành của dữ liệu gốc	16
Hình 5: Thông tin về bộ dữ liệu sau khi thêm cột.....	22
Hình 6: Các cột có giá trị bị thiếu	23
Hình 7: Code thực hiện xóa khoảng trống thừa trong ngày tháng.....	23
Hình 8: Code cập nhật lại các cột bị thiếu do khoảng trống thừa.....	23
Hình 9: Code đếm các giá trị năm không hợp lệ	24
Hình 10: Các giá trị lạ trong cột rating.....	24
Hình 11: 3 giá trị lạ trong cột rating.....	24
Hình 12: Số quan sát còn lại sau khi tiền xử lý dữ liệu	25
Hình 13: Biểu đồ phân phối các biến phân loại sau khi tiền xử lý dữ liệu.....	25
Hình 14: Biểu đồ phân phối nội dung theo năm thêm vào	26
Hình 15: Code line chart biểu diễn số lượng nội dung được thêm vào theo tháng (2017-2020)..	27
Hình 16: Biểu đồ đường biểu thị số lượng nội dung được thêm vào theo tháng (2017-2020)	28
Hình 17: Code xử lý dữ liệu để vẽ biểu đồ Dot Plot	29
Hình 18: Code vẽ biểu đồ Dot Plot.....	29
Hình 19: Biểu đồ Dot Plot trực quan mối quan hệ theo năm phát hành và thời lượng phim	30
Hình 20: Code xử lý dữ liệu để vẽ biểu đồ.....	31
Hình 21: Biểu đồ Dot Plot trực quan mối quan hệ theo năm phát hành và số mùa của show.....	31
Hình 22: Code vẽ thêm biểu đồ chi tiết về giai đoạn từ 2000-2020.....	32
Hình 23: Biểu đồ Scatter Plot trực quan mối quan hệ theo năm phát hành và số mùa của show (2000-2020)	33
Hình 24: Code xử lý dữ liệu để vẽ biểu đồ Bar Chart.....	34
Hình 25: Code vẽ biểu đồ Bar Chart phân tích số lượng Movies và TV show được phát hành (2017-2020)	34
Hình 26: Biểu đồ bar chart hiển thị số lượng Movie Và TV show qua từng năm (2017-2020) ...	35
Hình 27: Biểu đồ boxplot phân phối thời lượng của phim theo khu vực	36
Hình 28: Mã vẽ biểu đồ Chropleth thể hiện 20 quốc gia đứng đầu về số lượng nội dung	37
Hình 29: Kết quả biểu đồ Chropleth thể hiện 20 quốc gia đứng đầu về số lượng nội dung	37
Hình 30: Mã vẽ biểu đồ Cột đơn thể hiện khu vực đứng đầu về số lượng nội dung.....	38
Hình 31: Kết quả biểu đồ Cột đơn thể hiện 20 khu vực đứng đầu về số lượng nội dung.....	39

Hình 32: Code vẽ biểu đồ Cột đôi thể hiện 2 đạo diễn theo khu vực đứng đầu về số lượng nội dung.	40
Hình 33: Kết quả biểu đồ Cột đôi thể hiện 2 đạo diễn theo khu vực đứng đầu về số lượng nội dung.	40
Hình 34: Code vẽ biểu đồ Cột đơn thể hiện đạo diễn theo khu vực đứng đầu về số lượng phim truyền hình.	41
Hình 35: Kết quả biểu đồ Cột đơn thể hiện đạo diễn theo khu vực đứng đầu về số lượng phim truyền hình.	42
Hình 36: Mã vẽ biểu đồ Cột đơn thể hiện đạo diễn đứng đầu theo 6 quốc gia về số lượng phim.	42
Hình 37: Kết quả biểu đồ Cột đơn thể hiện đạo diễn đứng đầu theo 6 quốc gia về số lượng phim.	43
Hình 38: Mã vẽ biểu đồ Cột đơn thể hiện diễn viên đứng đầu theo 6 quốc gia về số lượng phim.	44
Hình 39: Kết quả biểu đồ Cột đơn thể hiện diễn viên đứng đầu theo 6 quốc gia về số lượng phim.	45
Hình 40: Biểu đồ Heatmap thể hiện tỷ lệ phần trăm loại độ dài phim theo quốc gia	46
Hình 41: Chuẩn bị cột để vẽ biểu đồ phân phối thể loại theo phim và chương trình TV	47
Hình 42: Code vẽ biểu đồ Phân phối theo thể loại của phim và chương trình TV	48
Hình 43: Phân phối theo thể loại của phim và chương trình TV	48
Hình 44: Chuẩn bị số liệu để vẽ biểu đồ tỉ lệ phim theo đối tượng của từng quốc gia.....	49
Hình 45: Code tỉ lệ phần trăm thể loại phim theo quốc gia.....	50
Hình 46: Biểu đồ tính tỷ lệ phần trăm thể loại phim theo quốc gia	50
Hình 47: Code tính số lượng nội dung của mỗi thể loại.....	51
Hình 48: Code vẽ biểu đồ chi tiết về top 20 thể loại phim có nhiều nội dung nhất.....	52
Hình 49: Top 20 thể loại phim có nhiều nội dung nhất.....	52
Hình 50: Biểu đồ Parallel phân phối châu lục, thời lượng và đối tượng mục tiêu.....	53
Hình 51: Code vẽ biểu đồ các chương trình TV có nhiều mùa nhất	54
Hình 52: Top 10 chương trình có nhiều mùa nhất.....	54
Hình 53: Các đặc trưng được đưa vào mô hình	55
Hình 54: Code xử lý các từ ngữ.....	56
Hình 55: Code loại bỏ các ký tự Non_Ascii	57
Hình 56: Code Tokenize văn bản	57
Hình 57: Công thức TF-IDF	58
Hình 58: Trích xuất đặc trưng	59
Hình 59: Code thực nghiệm PCA	60
Hình 60: Kết quả PCA.....	61
Hình 61: Thực hiện thuật toán Phân cụm Kmeans.....	62
Hình 62: Chỉ số Sillhouette.....	63

Hình 63: Thêm cột kmeans_cluster vào bộ dữ liệu.....	63
Hình 64: Sự khác biệt của content_type theo từng cụm.....	64
Hình 65: Số lượng nội dung có trong từng cụm	65
Hình 66: Số lượng các chương trình TV và Movie theo cụm.....	66
Hình 67: Top 10 quốc gia có số lượng show cao nhất trong cụm 0.....	67
Hình 68: Số lượng nội dung theo thể loại trong cụm 0.....	68
Hình 69: Thể loại và từ khóa xuất hiện nhiều trong cụm 0	69
Hình 70: Biểu đồ cột đơn Top 10 quốc gia có số lượng show cao nhất trong cụm 1.....	70
Hình 71: Số lượng nội dung theo thể loại trong cụm 1.....	71
Hình 72: Thể loại và từ khóa xuất hiện nhiều trong cụm 1	72
Hình 73: Biểu đồ cột đơn Top 10 quốc gia có số lượng show cao nhất trong cụm 2.	73
Hình 74: Biểu đồ cột đơn thể hiện số lượng thể loại trong cụm 2.....	74
Hình 75: Thể loại và từ khóa xuất hiện nhiều trong cụm 2	75
Hình 76: Biểu đồ cột đơn thể hiện số lượng thể loại trong cụm 3.....	76
Hình 77: Thể loại và từ khóa xuất hiện nhiều trong cụm 3	77
Hình 78: Số lượng nội dung theo thể loại trong cụm 4.....	79
Hình 79: Thể loại và từ khóa xuất hiện nhiều trong cụm 4	80
Hình 80: Biểu đồ cột đơn Top 10 quốc gia có số lượng show cao nhất trong cụm 5.....	81
Hình 81: Số lượng nội dung theo thể loại trong cụm 5.....	82
Hình 82: Thể loại và từ khóa xuất hiện nhiều trong cụm 5	83
Hình 83: Biểu đồ cột đơn Top 10 quốc gia có số lượng show cao nhất trong cụm 6.....	84
Hình 84: Biểu đồ cột đơn Số lượng thể loại nội dung trong cụm 6	85
Hình 85: Số lượng nội dung theo thể loại trong cụm 6.....	86
Hình 86: Bốn loại chính của hệ thống gợi ý	88
Hình 87: Tạo dataframe để triển khai Hệ thống gợi ý.....	89
Hình 88: Cập nhật lại index của dataframe	90
Hình 89: Tính độ tương đồng.....	90
Hình 90: Code xử lý khi nhận được đầu vào	90
Hình 91: Thực nghiệm Hệ thống gợi ý.....	91
Hình 92: Kết quả các bộ phim tương tự “Dick Johnson Is Dead”.....	91
Hình 93: Kết quả các bộ phim tương tự “Peaky Blinders”.....	92
Hình 94: Kết quả nếu bộ phim không tồn tại trong bộ dữ liệu.....	93

LỜI MỞ ĐẦU

Trong thời đại bùng nổ thông tin và phát triển vượt bậc của công nghệ, việc khai thác và phân tích dữ liệu đã trở thành công cụ quan trọng trong hầu hết các lĩnh vực xã hội khác nhau. Với sự phổ biến của các nền tảng giải trí trực tuyến như Netflix, khối lượng dữ liệu khổng lồ đến từ hành vi người dùng đang được thu thập mỗi ngày và tăng lên một cách nhanh chóng.

Điều này đồng thời mở ra cơ hội lớn cho việc tìm hiểu và phân tích xu hướng, sở thích và tiềm năng của người dùng trong tương lai. Trong nghiên cứu này, đề tài tập trung trực quan hóa và phân tích bộ dữ liệu từ Netflix. Ở phần mở rộng, nhóm đã nghiên cứu các lý thuyết liên quan và xây dựng một hệ thống gợi ý, giúp đề xuất các bộ phim có sự tương đồng.

Từ khóa: Netflix, Phân tích dữ liệu, Trực quan dữ liệu, Hệ thống gợi ý.

CHƯƠNG I: TỔNG QUAN ĐỀ TÀI

1. Sơ lược đề tài

Trong thời đại bùng nổ thông tin và sự phát triển vượt bậc của công nghệ, dữ liệu trở thành tài nguyên quý giá, đóng vai trò then chốt trong việc định hình kinh doanh và cung cấp các dịch vụ cá nhân hóa. Cũng chính vì vậy, việc thu thập và phân tích dữ liệu trở thành một công cụ chiến lược, giúp các doanh nghiệp hiểu sâu hơn về hành vi khách hàng, hỗ trợ cho mục tiêu tối ưu hóa các dịch vụ của mình. Ngành giải trí trực tuyến phải đối mặt những thách thức lớn trong việc cá nhân hóa trải nghiệm người dùng nhằm tăng cường sự hài lòng và gắn bó của khách hàng.

Netflix, một trong những nền tảng giải trí trực tuyến lớn nhất thế giới, sở hữu một khối lượng dữ liệu khổng lồ đến từ hàng triệu người dùng trên thế giới với hành vi và sở thích đa dạng. Bằng cách sử dụng các kỹ thuật phân tích và trực quan hóa, việc xử lý và khai thác tập dữ liệu này để từ đó cung cấp một hệ thống gợi ý phim phù hợp là hoàn toàn khả thi.

2. Mục tiêu nghiên cứu

Nghiên cứu này tập trung vào việc trực quan và phân tích bộ dữ liệu về các nội dung được xuất bản trên Netflix. Thông qua đó, nhóm tác giả đã ứng dụng các kỹ thuật học máy và khai phá dữ liệu để xây dựng hệ thống gợi ý (Recommender System) dựa trên nội dung và mô tả phim, giúp đề xuất các nội dung phù hợp với đặc điểm của từng bộ phim, từ đó nâng cao trải nghiệm người dùng.

3. Phương pháp nghiên cứu

Nhóm sử dụng nhiều phương pháp nghiên cứu khác nhau, phù hợp với từng nội dung nghiên cứu:

- Khám phá dữ liệu (EDA): Sử dụng các biểu đồ trực quan nhằm làm nổi bật mục tiêu nghiên cứu và thể hiện rõ mối liên hệ giữa các biến số.
- Các loại biểu đồ: Sử dụng các loại biểu đồ chuyên dụng và phù hợp với mục đích trực quan hóa các dữ liệu, giúp người đọc báo cáo dễ dàng nắm bắt các thông tin quan trọng.
- Giảm chiều dữ liệu bằng phương pháp PCA: Tập trung vào việc rút gọn và giữ lại những đặc trưng quan trọng nhất, giúp tối ưu hóa quá trình phân tích và mô hình hóa dữ liệu.
- K means: Phân nhóm dữ liệu thành các cụm dựa trên các đặc điểm tương đồng.
- Cosine Similarity: Đo lường mức độ tương đồng giữa các vectơ trong không gian đa chiều.
- TF-IDF: Chuyển đổi văn bản thành dữ liệu số bằng cách đánh giá tầm quan trọng của các từ trong văn bản.

4. Tài nguyên sử dụng

- Ngôn ngữ Python: sử dụng để phân tích và biểu diễn trực quan.
- Bộ dữ liệu Netflix Movies and TV Shows từ Kaggle: [Link](#)

CHƯƠNG II: TỔNG QUAN BỘ DỮ LIỆU

1. Sơ lược về bộ dữ liệu

Bộ dữ liệu Netflix Movies and TV shows được nhóm lấy nguồn từ kaggle, cung cấp thông tin chi tiết về các bộ phim và chương trình truyền hình trên Netflix. Bộ dữ liệu dùng để phân tích nội dung các bộ phim và chương trình trên Netflix, bao gồm các thể loại, năm phát hành, quốc gia sản xuất, và thời lượng. Điều này giúp xác định xu hướng nội dung hoặc phân loại dữ liệu theo đặc điểm.

2. Mô tả thuộc tính của bộ dữ liệu

Bộ dữ liệu bao gồm các thuộc tính sau:

Thuộc tính	Ý nghĩa	Chú thích
show_id	Mã định danh duy nhất cho mỗi bộ phim hoặc chương trình	
type	Loại nội dung (phim hoặc tv show)	Có 2 giá trị là Movie và TV show
title	Tên phim/tên chương trình	
director	Tên đạo diễn	
cast	Danh sách các diễn viên tham gia	
country	Quốc gia sản xuất	
date_added	Ngày mà phim/chương trình được thêm vào Netflix	
release_year	Năm phát hành phim/chương trình	Từ năm 1925 đến 2021
rating	Xếp hạng đánh giá độ tuổi phù hợp cho phim/chương trình	Bao gồm các giá trị như: TV-MA, PG-13, R, TV-14, TV_PG
duration	Thời lượng của bộ phim/chương trình	Movie tính theo phút, TV Show tính theo số mùa.
listed_in	Thể loại của phim/chương trình	Có thể có nhiều giá trị trong quan sát, ngăn cách bởi dấu phẩy

description	Mô tả ngắn về bộ phim/chương trình	
-------------	------------------------------------	--

Bảng 1: Mô tả ý nghĩa các cột dữ liệu ban đầu

3. Mô tả tổng quan bộ dữ liệu ban đầu

3.1. Thông tin cơ bản

Để hiểu rõ về bộ dữ liệu, nhóm cần biết những thông tin cơ bản như số lượng quan sát (dòng), số lượng biến (cột), và các thông tin mô tả về các biến trong bộ dữ liệu. Điều này giúp xác định quy mô của dự án và tạo nền tảng cho các quyết định về phân tích và xử lý dữ liệu.

```
Số lượng quan sát: 8807
Số lượng cột: 12

Các cột hiện có bao gồm:
show_id
type
title
director
cast
country
date_added
release_year
rating
duration
listed_in
description
```

Hình 1: Số lượng hàng và cột của bộ dữ liệu ban đầu

Từ kết quả ở trên, nhóm đã thu được thông tin rằng: bộ dữ liệu chứa tổng cộng 8807 quan sát và 12 cột thuộc tính. Số lượng quan sát cho biết mức độ lớn của dữ liệu, trong khi số lượng cột cho biết có bao nhiêu biến được quan tâm. Sau khi hiểu rõ về quy mô này, nhóm sẽ tiếp tục thực hiện phân tích và xử lý dữ liệu.

3.2. Kiểm tra dữ liệu

Đây là bước quan trọng trong quá trình tiền xử lý dữ liệu, giúp phát hiện và xử lý giá trị trống (missing values) cũng như các giá trị bất thường có thể ảnh hưởng đến kết quả của

phân tích dữ liệu. Quá trình này đảm bảo tính nhất quán và độ tin cậy của dữ liệu trước khi tiến hành các bước phân tích tiếp theo.

```
Tổng số dòng: 8807
Tổng số cột: 12

Số giá trị bị thiếu trong mỗi cột:
director      2634
cast          825
country        831
date_added    10
rating         4
duration       3
dtype: int64

Tổng số giá trị bị thiếu: 4307
```

Hình 2: Số giá trị bị thiếu trong mỗi cột


Trong quá trình kiểm tra, các giá trị trống trong bộ dữ liệu được phát hiện như sau:

- director: 2634 giá trị bị thiếu, chiếm phần lớn dữ liệu, đây là trường cần lưu ý xử lý hoặc bỏ qua trong phân tích.
- cast: 825 giá trị bị thiếu, liên quan đến danh sách diễn viên.
- country: 831 giá trị bị thiếu, chiếm tỷ lệ lớn trong dữ liệu.
- date_added: 10 giá trị bị thiếu.
- rating: 4 giá trị bị thiếu.
- duration: 3 giá trị bị thiếu.

3.3. Trực quan hóa dữ liệu

Vẽ biểu đồ phân phối cho các cột dữ liệu (**type**, **rating**, **director**, **country**)

Biểu đồ phân phối các biến phân loại



Hình 3: Các biểu đồ phân phối cho dữ liệu phân loại của dữ liệu gốc

70% nội dung được phát hành trên Netflix là phim lẻ. Movie chiếm tỷ lệ lớn hơn hẳn (hơn 6,000) so với TV Show (khoảng 2,000). Xu hướng nội dung trên nền tảng này tập trung nhiều vào các bộ phim hơn là chương trình truyền hình.


TV-MA (dành cho người trưởng thành) là loại rating phổ biến nhất, chiếm hơn 3,000 nội dung. Đây là nhãn được gán cho các bộ phim dành cho người trưởng thành. Đồng thời, TV-14 (phim không phù hợp với đối tượng trẻ em dưới 14 tuổi) đứng ở vị trí thứ 2. Hai số liệu trên phản ánh rõ nền tảng này tập trung chủ yếu cho đối tượng trẻ vị thành niên đến người trưởng thành. Điều này cho thấy xu hướng trên Netflix tập trung nhiều vào nội dung dành cho người lớn hoặc thanh thiếu niên, ít đầu tư vào nội dung gia đình hoặc trẻ em.

Mỹ là quốc gia sản xuất nhiều phim nhất với hơn 3,500 nội dung được sản xuất, vượt trội so với các quốc gia còn lại. Điều này cho thấy Mỹ là trung tâm sản xuất nội dung lớn nhất trên nền tảng. Ấn Độ và Anh là hai quốc gia có số lượng phim đóng góp theo sau.

Hai đạo diễn Raul Campos và Jan Suter cùng chiếm vị trí đầu bảng, với khoảng 18 bộ phim. Các đạo diễn nổi tiếng khác như Marcus Raboy, Martin Scorsese, Steven Spielberg cũng có mặt nhưng số lượng phim thấp hơn.

Ngoài ra, một điểm đáng chú ý trong bộ dữ liệu là sự xuất hiện của nhiều giá trị được ghi nhận trên cùng một hàng ở các cột như country và director. Những giá trị được

ghi nhận theo dạng "danh sách" này sẽ tạo ra thách thức trong việc xử lý dữ liệu nếu cần phân tích riêng lẻ từng giá trị, như phân tích số lượng nội dung theo từng quốc gia hoặc từng đạo diễn. Do đó, để phân tích chính xác, cần phải xử lý riêng biệt các dữ liệu này.



Hình 4: Biểu đồ phân phối nội dung theo năm phát hành của dữ liệu gốc

Biểu đồ trên phản ánh xu hướng phát hành nội dung của Netflix qua các năm, từ năm 2010 đến năm 2021. Từ kết quả trên, ta thấy rằng giai đoạn 2010 - 2014, mức độ phát hành nội dung trên Netflix tăng chậm và duy trì ở mức độ thấp, khoảng 200–300 nội dung mỗi năm. Từ năm 2015, đặc biệt là giai đoạn từ năm 2015 đến 2019, số lượng nội dung phát hành trên Netflix tăng đáng kể. Số lượng nội dung phát hành đạt đỉnh cao trong năm 2018 và 2019, vượt qua 1.200 nội dung mỗi năm. Điều này có thể phản ánh sự mở rộng nhanh chóng của Netflix khi họ đầu tư mạnh vào sản xuất nội dung gốc (Original Content) để cạnh tranh với các nền tảng khác. Đến năm 2020, mặc dù vẫn duy trì ở mức cao, lượng nội dung phát hành trên Netflix đã giảm nhẹ so với năm 2019. Năm 2021 ghi nhận sự sụt giảm lớn hơn, chỉ còn khoảng 700 nội dung được phát hành. Nguyên nhân có thể đến từ đại dịch COVID-19, làm gián đoạn sản xuất nội dung trên toàn cầu. Biểu đồ phản ánh rõ sự chuyển đổi chiến lược của Netflix thành nhà sản xuất nội dung lớn nhất thế giới.

CHƯƠNG III: ĐỊNH DẠNG VÀ Ý NGHĨA CỦA BỘ DỮ LIỆU

TÊN CỘT	Ý NGHĨA / GIẢI THÍCH	CÁC GIÁ TRỊ XÁC ĐỊNH
month_added	Định nghĩa: là tháng trong năm mà phim/chương trình được thêm vào Netflix. <u>Mục tiêu của việc thêm cột:</u> theo dõi xu hướng phát hành nội dung trên Netflix theo tháng trong năm.	<u>Miền giá trị:</u> - Cột month_added chứa các giá trị số trong khoảng [1; 12] tương ứng từ tháng 1 đến tháng 12. - Giá trị của cột month_added sẽ phụ thuộc vào giá trị của cột date_added. <u>Ví dụ:</u> nếu giá trị của cột date_added là “September 25, 2021” thì giá trị của cột month_added sẽ là 9.
year_added	Định nghĩa: là năm mà phim/chương trình được thêm vào Netflix. <u>Mục tiêu của việc thêm cột:</u> theo dõi xu hướng phát hành nội dung trên Netflix theo năm.	<u>Miền giá trị:</u> - Cột year_added chứa các giá trị số trong khoảng [1925; 2021] tương ứng từ năm 1925 đến năm 2021. - Giá trị của cột year_added sẽ phụ thuộc vào giá trị của cột date_added. <u>Ví dụ:</u> nếu giá trị của cột date_added là “September 25, 2021” thì giá trị của cột year_added sẽ là 2021.
has_seasons	Định nghĩa: là số mùa được chiếu của bộ phim/chương trình được thêm vào Netflix. <u>Mục tiêu của việc thêm cột:</u>	<u>Miền giá trị:</u> Cột has_seasons chứa các giá trị chuỗi trong khoảng [1; 17] tương ứng số lượng mùa được chiếu của bộ

TÊN CỘT	Ý NGHĨA / GIẢI THÍCH	CÁC GIÁ TRỊ XÁC ĐỊNH
	- Dễ dàng phân loại nội dung thành phim lẻ (1 mùa) hoặc phim/series nhiều mùa. - Hỗ trợ trong việc phân tích nội dung theo số lượng mùa.	phim. Đối với các bộ phim / chương trình không được chiếu dài tập (theo mùa) thì giá trị của cột has_seasons sẽ là “has no season”. Giá trị của cột has_seasons sẽ phụ thuộc vào giá trị của cột duration. <u>Ví dụ:</u> nếu giá trị của cột duration là “2 Seasons” thì giá trị của cột has_seasons sẽ là “2”.
duration_minutes	Định nghĩa: là số phút được chiếu của bộ phim/chương trình không được chiếu dài tập trên Netflix. <u>Mục tiêu của việc thêm cột:</u> - Giúp phân chia phim và chương trình thành các nhóm dựa trên thời lượng. - Cung cấp tiêu chí lọc nội dung theo độ dài phim trên Netflix, giúp người dùng dễ dàng tìm thấy nội dung phù hợp.	<u>Miền giá trị:</u> - Cột duration_minutes chứa các giá trị chuỗi trong khoảng [3; 312] tương ứng số phút chiếu của bộ phim. Đối với các bộ phim / chương trình được chiếu dài tập (theo mùa) thì giá trị của cột duration_minutes sẽ là “is season”. - Giá trị của cột duration_minutes sẽ phụ thuộc vào giá trị của cột duration. <u>Ví dụ:</u> nếu giá trị của cột duration là “90 min” thì giá trị của cột duration_minutes sẽ là “90”.
duration_category	Định nghĩa: là thể loại của bộ	<u>Miền giá trị:</u>

TÊN CỘT	Ý NGHĨA / GIẢI THÍCH	CÁC GIÁ TRỊ XÁC ĐỊNH
	phim dựa trên thời lượng (số phút) chiếu của bộ phim đó. <u>Mục tiêu của việc thêm cột:</u> - Theo dõi và phân tích xu hướng tiêu thụ nội dung theo độ dài. - Giúp phân chia phim và chương trình thành các nhóm dựa trên thời lượng.	- Cột <code>duration_category</code> chứa 3 giá trị chuỗi bao gồm: “Short”, “Medium”, “Long” tương ứng với những bộ phim được chiếu dưới 60 phút, những bộ phim được chiếu từ 60-120 phút và những bộ phim được chiếu trên 120 phút. - Giá trị của cột <code>duration_category</code> sẽ phụ thuộc vào giá trị của cột <code>date_added</code>. <u>Ví dụ:</u> nếu giá trị của cột <code>duration</code> là “90 min” thì giá trị của cột <code>duration_category</code> sẽ là “Medium”.
<code>content_type</code>	<u>Định nghĩa:</u> là các thể loại của bộ phim/chương trình dựa trên các nhóm thích hợp với độ tuổi người xem <u>Mục tiêu của việc thêm cột:</u> - Giúp phân tích sự phân bố của các bộ phim/chương trình theo các nhóm. Từ đó, có thể xác định xu hướng về loại nội dung phổ biến nhất và phù hợp với từng nhóm người xem. - Xác định sự thành công của các loại nội dung dựa	<u>Miền giá trị:</u> - Cột <code>content_type</code> chứa 4 giá trị chuỗi bao gồm: “Adult”, “Teen”, “Family”, “Unknown”. - Trong đó: - Thể loại “Adult” sẽ dành cho những bộ phim / chương trình có phân loại độ tuổi là TV-MA, R, NC-17. - Thể loại “Teen” sẽ dành cho những bộ phim /

TÊN CỘT	Ý NGHĨA / GIẢI THÍCH	CÁC GIÁ TRỊ XÁC ĐỊNH
	trên đối tượng người xem để hiểu được sự phổ biến và mức độ hấp dẫn của từng thể loại. Phân tích sự thay đổi theo thời gian về nhu cầu nội dung cho từng nhóm độ tuổi.	chương trình có phân loại độ tuổi là TV-14, PG-13. - Thẻ loại “Family” sẽ dành cho những bộ phim / chương trình có phân loại độ tuổi là TV-PG, TV-Y, TV-Y7, TV-Y7-FV, G, PG. - Thẻ loại “Unknown” sẽ dành cho những bộ phim / chương trình có phân loại độ tuổi là NR, UR. - Giá trị của cột content_type sẽ phụ thuộc vào giá trị của cột rating. <u>Ví dụ:</u> nếu giá trị của cột rating là “TV-MA” thì giá trị của cột content_type sẽ là “Adult”.
region	Định nghĩa: là châu lục của những nước tham gia vào xây dựng nên phim/chương trình. <u>Mục tiêu của việc thêm cột:</u> Giúp hiểu rõ sự đa dạng về nguồn gốc của các bộ phim và chương trình trên Netflix, từ đó phân tích sự phổ biến và sự đóng góp của các khu vực khác nhau trong ngành công nghiệp điện ảnh và truyền hình.	<u>Miền giá trị:</u> - Cột region chứa các giá trị chuỗi là danh sách các châu lục của những nước tham gia vào bộ phim / chương trình. - Giá trị của cột region sẽ phụ thuộc vào giá trị của cột country. <u>Ví dụ:</u> nếu giá trị của cột country là “United States, Ghana, Burkina Faso, United Kingdom, Germany, Ethiopia” thì giá trị của cột region

TÊN CỘT	Ý NGHĨA / GIẢI THÍCH	CÁC GIÁ TRỊ XÁC ĐỊNH
	Phân tích mức độ phổ biến của nội dung từ từng khu vực và sự ảnh hưởng của các quốc gia, giúp Netflix đánh giá sự thành công của các bộ phim hoặc chương trình dựa trên khu vực sản xuất.	sẽ là “North America, Europe, Africa”.

Bảng 2: Định dạng và ý nghĩa của bộ dữ liệu

CHƯƠNG IV: TIỀN XỬ LÝ DỮ LIỆU

1. Thông tin cơ bản

Đầu tiên, nhóm thực hiện quan sát những thông tin cơ bản sau sửa đổi như số lượng quan sát (dòng), số lượng biến (cột), và các thông tin mô tả về các biến trong bộ dữ liệu.

Sau thay đổi, bộ dữ liệu đã có thêm 7 biến thuộc tính, bao gồm: **month_added**, **year_added**, **has_seasons**, **duration_minutes**, **duration_category**, **content_type** và **region**.

```
Số quan sát: 8807
Số lượng cột: 19
Các cột hiện có bao gồm:
show_id
type
title
director
cast
country
date_added
release_year
rating
duration
listed_in
description
month_added
year_added
has_seasons
duration_minutes
duration_category
content_type
region
```

Hình 5: Thông tin về bộ dữ liệu sau khi thêm cột

2. Kiểm tra dữ liệu

Tương tự như bộ dữ liệu ban đầu, nhóm cần thực hiện tìm và xử lý giá trị trống (missing values) cũng như các giá trị không hợp lệ (invalid values) có thể ảnh hưởng đến kết quả của phân tích dữ liệu.

Nhóm tiến hành quan sát kỹ các cột bị thiếu.

```
Các cột có giá trị bị thiếu:  
month_added: 98  
year_added: 98
```

Hình 6: Các cột có giá trị bị thiếu

Những cột có giá trị bị thiếu có điểm chung là liên quan đến ngày tháng. Các cột này đều được thêm dựa vào cột `date_added` trong bộ dữ liệu gốc

Sau khi quan sát, nhóm dự đoán được nguyên nhân dẫn đến dữ liệu bị thiếu đến từ việc lỗi nhập vào của `date_added` có các khoảng trống thừa.

```
# xóa dấu cách dư thừa cột date_added và release_year  
df['date_added'] = df['date_added'].str.lstrip()  
df['date_added'] = df['date_added'].str.rstrip()  
✓ 0.0s
```

Hình 7: Code thực hiện xóa khoảng trống thừa trong ngày tháng

Sau đó, nhóm tiến hành cập nhật lại các cột bị thiếu.

```
# Convert 'date_added' to datetime, handling errors by coercing them to NaT  
df['date_added_datetime'] = pd.to_datetime(df['date_added'], errors='coerce')  
  
# Add new columns, handling null values  
df['month_added'] = df['date_added_datetime'].dt.month.astype('Int64')  
df['year_added'] = df['date_added_datetime'].dt.year.astype('Int64')  
  
# Drop 'date_added_datetime' column  
df.drop('date_added_datetime', axis=1, inplace=True)  
✓ 0.0s
```

Hình 8: Code cập nhật lại các cột bị thiếu do khoảng trống thừa

Lúc này, dữ liệu bị thiếu chỉ còn 10 quan sát so với ban đầu.

Bên cạnh đó, nhóm quan sát thấy có những quan sát năm phát hành lớn hơn năm được thêm vào Netflix.

```
#count if year_added < release_year
count += df[df['year_added'] < df['release_year']].shape[0]
count
✓ 0.0s
14
```

Hình 9: Code đếm các giá trị năm không hợp lệ

Do đó, nhóm tiến hành xóa các giá trị này.

Nhóm quan sát thấy trong cột rating xuất hiện các giá trị lạ như 74 min, 84 min và 66 min.

```
#print unique values of column 'rating'
df['rating'].unique()
✓ 0.0s
array(['PG-13', 'TV-MA', 'PG', 'TV-14', 'TV-PG', 'TV-Y', 'TV-Y7', 'R',
      'TV-G', 'G', 'NC-17', '74 min', '84 min', '66 min', 'NR',
      'Unknown', 'TV-Y7-FV', 'UR'], dtype=object)
```

Hình 10: Các giá trị lạ trong cột rating

```
#count rows with rating = '74 min' or '84 min' or '66 min'
count = df[(df['rating'] == '74 min') | (df['rating'] == '84 min') | (df['rating'] == '66 min')].shape[0]
c_null += count
count
✓ 0.0s
3
Python
```

Hình 11: 3 giá trị lạ trong cột rating

Tổng số hàng của 3 quan sát đặc biệt này là 3, vì vậy, nhóm tiến hành xóa các giá trị này.

Số quan sát bị xóa trong quá trình này là 27, tổng số quan sát còn lại là 8783.


```
print('Số quan sát bị xóa: ', count)
print('Tổng số quan sát sau khi xóa: ', df.shape[0])
✓ 0.0s
Số quan sát bị xóa: 27
Tổng số quan sát sau khi xóa: 8783
```


Hình 12: Số quan sát còn lại sau khi tiền xử lý dữ liệu

3. Trực quan hóa dữ liệu

Về biểu đồ phân phối cho các cột dữ liệu (**content_type**, **duration_category**, **region**, **month_added**)

Biểu đồ phân phối các biến phân loại



Hình 13: Biểu đồ phân phối các biến phân loại sau khi tiền xử lý dữ liệu

Nhận xét về biểu đồ:


Phần lớn nội dung được phát hành trên Netflix là dành cho đối tượng vị thành niên và người trưởng thành. Bên cạnh đó, nội dung dành cho nhóm đối tượng gia đình vẫn xuất hiện và chiếm gần 25% trên tổng số.

Nội dung có thời lượng trung bình từ 60 – 120 phút chiếm gần 60% so với tổng số. Theo sau đó, các nội dung sản xuất nhiều mùa cũng chiếm một phần lớn trên nền tảng này. Nội ngắn (dưới 60 phút) dường như không phù hợp trên nền tảng này nên xuất hiện với tần

suất rất thấp.

Những nội dung do các quốc gia Châu Mỹ sản xuất xuất hiện với tần suất nổi bật, theo sau đó là các quốc gia đến từ Châu Á và Châu Âu. Bên cạnh đó, xuất hiện những bộ phim được sản xuất bởi 2 – 3 châu lục khác nhau.

Số lượng các phim được thêm vào mỗi tháng là khá đồng đều trong cả năm. Tuy nhiên, có thể thấy nửa cuối năm có sự đều và nhỉnh hơn một chút.



Hình 14: Biểu đồ phân phối nội dung theo năm thêm vào

Nhận xét về biểu đồ

Năm 2010 đến 2018 chứng kiến sự phát triển nhanh chóng của Netflix khi số lượng nội dung được thêm vào nền tảng Netflix tăng dần theo từng năm. Đặc biệt là vào năm 2019, số lượng nội dung được phát hành đạt mức cao nhất và chiếm đến 23% trên toàn bộ nền tảng. Điều này cho thấy sự mở rộng mạnh mẽ của nền tảng giải trí này.

Tuy nhiên, kể từ năm 2020, lượng nội dung giảm dần. Vào năm 2021, lượng nội dung được ghi nhận giảm tương đối mạnh. Một trong những yếu tố có thể kể đến là đại dịch Covid 19 đã khiến các nội dung ngừng bùng nổ trong thời gian ngắn, các chương trình và phim truyền hình rất khó để thực hiện và duy trì vì tình hình giãn cách của thế giới cùng thời điểm đó. Một lý do quan trọng khác, nội dung được thêm vào Netflix trong năm 2021 chỉ được ghi nhận đến hết tháng 9. Chính vì vậy mà lượng nội dung của bộ dữ liệu này có phần không phản ánh đúng nhất về số liệu của toàn năm 2021.

CHƯƠNG V: TRỰC QUAN HÓA DỮ LIỆU

1. Dòng thời gian (Times Series)

1.1. Số lượng nội dung được thêm vào theo tháng và năm

Nhóm thực hiện lọc các nội dung được thêm vào Netflix từ năm 2017-2020 và đếm số lượng nội dung được thêm vào Netflix cho từng tháng của từng năm. Đồng thời tạo danh sách các tháng từ tháng 1 - tháng 12.

```
# Lọc dữ liệu theo các năm mong muốn
df_filtered = df[df['year_added'].isin([2017, 2018, 2019, 2020])]

# Đếm số lượng phim được thêm vào mỗi tháng cho từng năm
monthly_data = df_filtered.groupby(['year_added', 'month_added']).size().reset_index(name='count')

# Chuẩn bị dữ liệu cho biểu đồ đường
months = range(1, 13) # 12 tháng
years = [2017, 2018, 2019, 2020]

# Vẽ biểu đồ
plt.figure(figsize=(10, 6))
for year in years:
    # Lấy dữ liệu theo năm
    data_by_year = monthly_data[monthly_data['year_added'] == year]
    counts = [data_by_year[data_by_year['month_added'] == month]['count'].sum() for month in months]


    # Vẽ đường
    plt.plot(months, counts, marker='o', label=str(year))

# Cấu hình biểu đồ
plt.title('Số lượng nội dung được thêm vào theo tháng (2017 - 2020)', fontsize=14)
plt.xlabel('Tháng', fontsize=12)
plt.ylabel('Số lượng nội dung', fontsize=12)
plt.xticks(months, fontsize=10)
plt.legend(title='Năm', loc='upper right')
plt.grid(axis='y', linestyle='--', alpha=0.7)

# Hiển thị biểu đồ
plt.tight_layout()
plt.show()
```

Hình 15: Code line chart biểu diễn số lượng nội dung được thêm vào theo tháng (2017-2020)

Kết quả:



Hình 16: Biểu đồ đường biểu thị số lượng nội dung được thêm vào theo tháng (2017-2020)

Biểu đồ đường trên cho thấy sự thay đổi số lượng nội dung được Netflix bổ sung vào hàng tháng trong bốn năm (2017, 2018, 2019, 2020).

Giai đoạn 2017-2018 cho thấy sự ổn định tương đối về số lượng nội dung được thêm vào mỗi tháng, dao động trong khoảng nội dung 75–175. Tháng 3 và tháng 10 năm 2017 có sự gia tăng nhẹ về số lượng nội dung, tuy nhiên không có sự biến đổi tối đa so với các tháng khác trong cùng giai đoạn. Điều này có thể phản ánh nội dung chiến lược phát triển đều đều trong năm mà không tập trung vào một thời điểm cụ thể.

Năm 2019, số lượng nội dung tăng đều qua tháng và đạt đỉnh vào tháng 11 với hơn 250 nội dung. Điều này có thể phản ánh nội dung chiến lược tăng cường sức mạnh của Netflix để thu hút người dùng vào mùa lễ hội cuối năm.

Đầu tháng 1 năm 2020, ghi nhận mức tăng biến động biến với gần 200 nội dung, nhưng sau đó giảm mạnh vào tháng 2 và ổn định ở mức thấp hơn trong nửa đầu năm. Vào các tháng cuối năm, số lượng nội dung vẫn duy trì ở mức cao hơn so với đầu năm, nhưng không đạt được đỉnh cao như năm 2019.

1.2. Biểu đồ chấm theo năm phát hành và thời lượng phim

Nhóm thực hiện tạo bản sao của các cột duration và release_year từ Dataframe gốc. Sau đó, nhóm tiến hành xử lý dữ liệu trong cột duration, loại bỏ các giá trị None trong cột này. Sau khi xử lý, nhóm in ra các giá trị duy nhất của cột duration để kiểm tra kết quả

```
# Chỉ lấy những phim ngắn tập (không có season)
temp_df = df[['release_year', 'duration']].copy()
temp_df['duration'] = temp_df['duration'].apply(lambda x: int(x.split()[0]) if 'Season' not in x else None)
temp_df = temp_df.dropna(subset=['duration'])

print(temp_df['duration'].unique())
```

Hình 17: Code xử lý dữ liệu để vẽ biểu đồ Dot Plot

Nhóm sử dụng biểu đồ Dot Plot để trực quan mối quan hệ theo năm phát hành và thời lượng phim để tìm hiểu xu hướng về thời lượng phim qua các năm.

```
# Vẽ biểu đồ dot plot
plt.figure(figsize=(12, 6))
sns.stripplot(data=temp_df, x='release_year', y='duration', color='blue', alpha=0.6)

# Cấu hình biểu đồ
plt.title('Thời lượng trung bình của phim theo năm', fontsize=14)
plt.xlabel('Năm', fontsize=12)
plt.ylabel('Thời lượng (phút)', fontsize=12)
temp_df = temp_df.sort_values(by='release_year')
xticks = temp_df['release_year'].unique()
xtick_labels = [str(year) if year % 5 == 0 else '' for year in xticks]
plt.xticks(ticks=range(len(xticks)), labels=xtick_labels, fontsize=10)
plt.tick_params(axis='x', which='both', bottom=False)


for i, year in enumerate(xticks):
    if year % 5 == 0:
        plt.axvline(x=i, color='gray', alpha=0.2)

plt.yticks(fontsize=10)
plt.grid(axis='y', linestyle='--', alpha=0.7)

# Hiển thị biểu đồ
plt.tight_layout()
plt.show()
```

Hình 18: Code vẽ biểu đồ Dot Plot

Kết quả:



Hình 19: Biểu đồ Dot Plot trực quan mối quan hệ theo năm phát hành và thời lượng phim

Biểu đồ chấm (Dot Plot) trên hiển thị mối quan hệ giữa năm phát hành và thời lượng phim. Mỗi điểm trên biểu đồ đại diện cho một bộ phim hoặc chương trình, với x là năm phát hành và y là thời lượng phim.

Giai đoạn trước năm 1970, số lượng phim phát hành ít, phân bố rải rác với thời lượng trung bình khoảng từ 50–150 phút. Giai đoạn từ năm 1970-2000, cho thấy sự gia tăng về số lượng phim, nhưng thời lượng vẫn giữ trong khoảng từ 50 đến 150 phút. Bên cạnh đó vẫn có những bộ phim có thời lượng dài hơn 200 phút, nhưng số lượng vẫn chưa có nhiều.

Sau năm 2000, số lượng phim tăng lên đáng kể, phản ánh sự phát triển nhanh chóng của ngành công nghiệp giải trí. Từ năm 2010 trở đi, sự xuất hiện dày đặc của các điểm trên biểu đồ cho thấy sự bùng nổ trong việc phát hành nội dung bao gồm cả phim và chương trình truyền hình trên Netflix. Hầu hết các phim có thời lượng trong khoảng từ 50 đến 120 phút và ít phim có thời lượng dài hơn 200 phút.

Ngoài ra, trên biểu đồ còn xuất hiện một số điểm dữ liệu có thời lượng dưới 50 phút, đây có thể là các chương trình TV đặc biệt, tập phim ngắn hoặc phim hoạt hình. Và một số phim dài hơn 250 phút có thể là các phim tài liệu hoặc sử thi.

1.3. Biểu đồ chấm theo năm phát hành và số mùa của TV show

Nhóm thực hiện tạo bảng tạm `temp_df` chỉ chứa các hàng mà cột `has_seasons` không có giá trị 'has no season' và chỉ giữ lại hai cột là `release_year` và `has_seasons` trong `temp_df`. Sau đó nhóm thực hiện kiểm tra dữ liệu.


```
[ ] # Lọc dữ liệu từ năm 2000 đến 2020 và chọn những chương trình dài tập
temp_df = df[df['has_seasons'] != 'has no season']
temp_df = temp_df[['release_year', 'has_seasons']]
temp_df['has_seasons'] = temp_df['has_seasons'].apply(lambda x: int(x.split()[0]))
temp_df = temp_df.sort_values(by='has_seasons')

# Lọc dữ liệu từ năm 2000 đến 2020
df_filtered = df[(df['release_year'] >= 2000) & (df['release_year'] <= 2020)]
temp_df = df_filtered[df_filtered['has_seasons'] != 'has no season']
temp_df = temp_df[['release_year', 'has_seasons']]
temp_df['has_seasons'] = temp_df['has_seasons'].apply(lambda x: int(x.split()[0]))

print(temp_df.head(10))
```

Hình 20: Code xử lý dữ liệu để vẽ biểu đồ

Nhóm thực hiện vẽ biểu đồ Scatter Plot trực quan hoá mối quan hệ theo năm phát hành và số mùa của show.



Hình 21: Biểu đồ Dot Plot trực quan mối quan hệ theo năm phát hành và số mùa của show

Biểu đồ Dot Plot trên minh họa mối quan hệ giữa năm phát hành (trục x) và số mùa (trục y) của các chương trình truyền hình (Show) trên Netflix. Mỗi điểm trên biểu đồ đại diện cho một chương trình với tọa độ x là năm phát hành và tọa độ y là số mùa mà chương

trình có.

Giai đoạn trước năm 2000, biểu đồ thể hiện số lượng điểm dữ liệu thấp, phản ánh việc sản xuất chương trình truyền hình trước năm 2000 còn hạn chế. Các chương trình thường chỉ có từ 1 đến 2 mùa và rất ít chương trình có số mùa vượt qua con số này.

Giai đoạn sau năm 2000, số lượng điểm dữ liệu tăng lên đáng kể, cho thấy sự gia tăng mạnh mẽ trong việc sản xuất nội dung cho các series truyền hình và phần lớn các chương trình có khoảng từ 1-3 mùa. Một số chương trình có từ 5 đến hơn 10 mùa, cho thấy sức hút lâu dài và thành công của những series này.

Vì từ năm 2000-2020, số lượng show được phát hành nhiều hơn và các season bị chồng lấp lên nhau dẫn đến việc khó quan sát hơn, nhóm đã biểu diễn một biểu đồ chi tiết hơn áp dụng kỹ thuật dịch điểm jittering về giai đoạn này:


```
# Cấu hình tiêu đề và nhãn trục
plt.figure(figsize=(12, 6))
plt.title('Phân phối nội dung theo số lượng mùa', fontsize=14)
plt.xlabel('Năm phát hành', fontsize=12)
plt.ylabel('Số mùa', fontsize=12)

# Vẽ dot plot với jitter
sns.stripplot(
    data=temp_df,
    x='release_year',
    y='has_seasons',
    color='blue',
    alpha=0.6,
    jitter=True # Thêm jitter để tránh chồng lấp
)

# Vẽ lưới
plt.grid(axis='y', linestyle='--', alpha=0.7)

# Hiển thị biểu đồ
plt.tight_layout()
plt.show()
```

Hình 22: Code vẽ thêm biểu đồ chi tiết về giai đoạn từ 2000-2020



Hình 23: Biểu đồ Scatter Plot trực quan mối quan hệ theo năm phát hành và số mùa của show (2000-2020)

Từ năm 2000-2010, rất ít chương trình truyền hình được phát hành, các chương trình được phát hành hầu hết chỉ có 1 hoặc 2 mùa. Một số ít chương trình có 3-6 mùa, đại diện cho các chương trình thành công trong thời kỳ đầu, như các series truyền thống hoặc chương trình truyền hình nổi tiếng.

Giai đoạn 2010-2015, số lượng chương trình bắt đầu có sự tăng nhẹ. Phần lớn chương trình vẫn chỉ có 1-2 mùa, nhưng các chương trình dài từ 4-6 mùa cũng đã xuất hiện nhiều hơn, báo hiệu sự thay đổi trong chiến lược sản xuất. Điều này có thể phản ánh sự chuyển dịch của ngành công nghiệp giải trí khi dần đầu tư nhiều hơn vào các series.

Từ năm 2015-2020, số lượng chương trình tăng đột biến, các chương trình chủ yếu có 1-3 mùa, nhưng đáng chú ý hơn là sự xuất hiện của những chương trình dài với hơn 10 mùa. Năm 2015 đã có sự gia tăng mạnh mẽ về cả số lượng chương trình lẫn sự đa dạng trong số mùa.

Giai đoạn trước năm 2010 là thời kỳ mà các chương trình truyền hình truyền thống chiếm ưu thế. Tuy nhiên, cùng với sự phát triển của công nghệ và sự ra đời của các nền tảng streaming, ngành công nghiệp đã chuyển mình mạnh mẽ, khán giả ngày càng đòi hỏi nội dung mới mẻ và nhanh chóng. Điều này giải thích cho sự gia tăng số lượng chương trình ngắn hạn, nhưng đồng thời các series dài tập vẫn duy trì vị thế nhờ cộng đồng người xem trung thành.

1.4. Số lượng phim và chương trình TV theo năm

Nhóm thực hiện lọc dữ liệu các năm phát hành và nhóm dữ liệu theo `release_year` (năm

phát hành), type (loại nội dung), đồng thời tính tổng số lượng nội dung cho các loại.

```
# Filter the data for the years 2017 to 2020
filtered_df = df[(df['release_year'] >= 2017) & (df['release_year'] <= 2020)]

# Group the data by year and type
type_counts = filtered_df.groupby(['release_year', 'type']).size().reset_index(name='count')

# Tính tổng số nội dung mỗi năm
year_totals = type_counts.groupby('release_year')['count'].transform('sum')
type_counts['percentage'] = (type_counts['count'] / year_totals * 100).round(1)
```

Hình 24: Code xử lý dữ liệu để vẽ biểu đồ Bar Chart

Nhóm sử dụng sns.barplot để vẽ biểu đồ bar chart hiển thị số lượng Movies và TV Shows cho từng năm.

```
# Plot the data
plt.figure(figsize=(10, 6))
barplot = sns.barplot(
    data=type_counts,
    x='release_year',
    y='count',
    hue='type',
    palette='muted'
)


# Customize the plot
plt.title('Count of Movies and TV Shows by Year (2017-2020)', fontsize=14, fontweight='bold')
plt.xlabel('Year', fontsize=12)
plt.ylabel('Count', fontsize=12)
plt.legend(title='Type', fontsize=10, title_fontsize=12)
plt.xticks(fontsize=10)
plt.yticks(fontsize=10)
plt.grid(axis='y', linestyle='--', alpha=0.7)

# Ensure bars are in front of the grid
for bar in plt.gca().patches:
    bar.set_zorder(2)

# Show the plot
plt.tight_layout()
plt.show()
```

Hình 25: Code vẽ biểu đồ Bar Chart phân tích số lượng Movies và TV show được phát hành (2017-2020)

Kết quả:



Hình 26: Biểu đồ bar chart hiển thị số lượng Movie Và TV show qua từng năm (2017-2020)

Biểu đồ thể hiện số lượng phim (Movie) và chương trình truyền hình (TV Show) được phát hành trên Netflix từ năm 2017 đến năm 2020. Các thanh màu xanh đại diện cho phim, trong khi thanh màu cam đại diện cho chương trình truyền hình.

Năm 2017, số lượng phim phát hành chiếm ưu thế với 766 nội dung, trong khi chương trình TV chỉ có 264 nội dung. Điều này cho thấy Netflix vẫn đang phát hành phim nhiều hơn là chương trình truyền hình trong giai đoạn này.

Năm 2018, số lượng phim phát hành giữ nguyên ở mức khoảng hơn 700 nội dung, con số không tăng đáng kể so với năm 2017. Tuy nhiên, số lượng chương trình truyền hình đã tăng lên 378 nội dung, cho thấy sự chuyển dịch dần trong chiến lược mở rộng danh mục nội dung của Netflix.


Đến năm 2019, số lượng phim phát hành giảm xuống 632 nội dung, đánh dấu sự giảm xuống lần đầu tiên về số lượng phim phát hành trên Netflix so với các năm trước. Ngược lại, chương trình truyền hình tiếp tục tăng lên với 395 nội dung, cho thấy Netflix đã bắt đầu đầu tư mạnh hơn vào nội dung dài hạn như series truyền hình.

Và năm 2020, số lượng phim giảm tiếp xuống còn khoảng 517 nội dung, nhưng chương trình TV lại tiếp tục tăng mạnh lên với 432 nội dung, gần đạt mức cân bằng với phim. Điều này phản ánh chiến lược rõ ràng của Netflix nhằm đa dạng hóa nội dung để đáp ứng nhu cầu của nhiều đối tượng khán giả hơn. Năm 2020 là bước ngoặt khi số lượng chương trình TV gần bắt kịp số lượng phim, cho thấy chiến lược của Netflix ngày càng hướng đến sự cân bằng giữa hai loại nội dung này. Đồng thời cũng phản ánh nhu cầu của

người xem khi họ tìm kiếm cả nội dung ngắn hạn (phim) và dài hạn (TV Show) để giải trí.

2. Vị trí địa lý

2.1. Phân phối thời lượng của phim theo khu vực




2.2. Những quốc gia có nhiều nội dung nhất

```
#visualize top 10 countries with most contents
top_countries = sorted(country_count.items(), key=lambda x: x[1], reverse=True)[:20]
top_countries = dict(top_countries)

# Vẽ biểu đồ
plt.figure(figsize=(12, 6))
sbn.barplot(x=list(top_countries.values()), y=list(top_countries.keys()), palette='viridis')
plt.title('Top 20 quốc gia có nhiều nội dung nhất')
plt.xlabel('Số lượng nội dung')
plt.ylabel('Quốc gia')
plt.grid(axis='x', linestyle='--', alpha=0.7)
plt.show()
```

Hình 28: Mã vẽ biểu đồ Chropleth thể hiện 20 quốc gia đứng đầu về số lượng nội dung

Trong đó, mảng `country_count` lưu giá trị đếm số lần xuất hiện của mỗi quốc gia.



Hình 29: Kết quả biểu đồ Chropleth thể hiện 20 quốc gia đứng đầu về số lượng nội dung

Biểu đồ trên thể hiện số lượng nội dung theo từng quốc gia giúp hiểu rõ sự phân bố nội dung trên nền tảng Netflix. Đứng đầu danh sách là Hoa Kỳ, với hơn 3500 nội dung, cho thấy vị thế thống trị của nước này trong ngành giải trí. Điều này không chỉ phản ánh sự phát triển mạnh mẽ của các studio sản xuất mà còn là nhờ vào những khoản đầu tư khổng lồ cho nội dung gốc phát trực tuyến trên Netflix.

Ấn Độ theo sát với khoảng 1000 nội dung, cho thấy sự bùng nổ của ngành điện ảnh và truyền hình tại đây. Nền văn hóa đa dạng và nhu cầu nội dung địa phương ngày càng

gia tăng đã thúc đẩy các nhà sản xuất Ấn Độ tạo ra nhiều sản phẩm phục vụ không chỉ cho thị trường trong nước mà còn cho khán giả quốc tế.

Tiếp theo là Anh và nhóm thuộc diện “không xác định” với khoảng 800 nội dung. Điều này cho thấy sự hiện diện mạnh mẽ của các chương trình truyền hình và phim điện ảnh từ Anh, nơi nổi tiếng với những series chất lượng cao như "The Crown" và "Sherlock". Số liệu cũng phản ánh các nội dung không rõ nguồn gốc chưa được xếp loại.

Insight từ biểu đồ cho thấy mặc dù còn thua Hoa Kỳ nhưng đã có sự phát triển ấn tượng của các quốc gia như Ấn Độ và Anh, nơi các sản phẩm văn hóa độc đáo đã thu hút được sự quan tâm lớn từ khán giả toàn cầu.

Bên cạnh đó, xu hướng toàn cầu hóa đang tạo ra cơ hội cho sự giao thoa văn hóa trong ngành giải trí. Người tiêu dùng hiện nay tìm kiếm trải nghiệm phong phú, không chỉ giới hạn trong nước. Điều này đòi hỏi các nhà sản xuất phải hợp tác quốc tế trong sản xuất nội dung giúp tạo ra sản phẩm đa dạng và hấp dẫn hơn. Những sản phẩm chất lượng cao, kết hợp các yếu tố văn hóa khác nhau, từ đó gia tăng sức hấp dẫn trên thị trường toàn cầu.


2.3. Số lượng nội dung theo châu lục

```
#visualize top 20 region with most contents
top_regions = sorted(region_count.items(), key=lambda x: x[1], reverse=True)[:20]
top_regions = dict(top_regions)

# Vẽ biểu đồ
plt.figure(figsize=(12, 6))
sbn.barplot(x=list(top_regions.values()), y=list(top_regions.keys()), palette='viridis')
plt.title('Top 20 khu vực có nhiều nội dung nhất')
plt.xlabel('Số lượng nội dung')
plt.ylabel('Khu vực')
plt.grid(axis='x', linestyle='--', alpha=0.7)
plt.show()
```

Hình 30: Mã vẽ biểu đồ Cột đơn thể hiện khu vực đứng đầu về số lượng nội dung

Trong đó, mảng `region_count` lưu giá trị đếm số lần xuất hiện của mỗi khu vực.



Hình 31: Kết quả biểu đồ Cột đơn thể hiện 20 khu vực đứng đầu về số lượng nội dung

Biểu đồ cột đơn về số lượng nội dung theo khu vực/châu lục cho thấy Bắc Mỹ dẫn đầu với khoảng 4000 nội dung, phản ánh sức mạnh vượt trội của ngành công nghiệp giải trí tại đây. Sự phát triển mạnh mẽ của Hollywood cùng với các khoản đầu tư lớn từ các nền tảng phát trực tuyến đã tạo ra một kho nội dung phong phú và đa dạng. Châu Á đứng thứ hai với gần 2500 nội dung, thể hiện sự gia tăng nhanh chóng của ngành giải trí, đặc biệt từ các quốc gia như Ấn Độ và Hàn Quốc, nơi nhiều bộ phim và series truyền hình đã thu hút sự chú ý toàn cầu.

Châu Âu xếp thứ ba với khoảng 1750 nội dung. Mặc dù số lượng không đạt được như Bắc Mỹ và Châu Á, nhưng châu lục này mang đến nhiều sản phẩm chất lượng cao, đặc biệt từ các quốc gia như Anh và Pháp. Điều này cho thấy rằng chất lượng có thể tạo ra sự khác biệt trong việc thu hút khán giả, và các nhà sản xuất châu Âu cũng có cơ hội để phát triển các sản phẩm ấn tượng.

Insight từ biểu đồ chỉ ra sự chênh lệch lớn giữa Bắc Mỹ và các châu lục khác, đặt ra thách thức cho các khu vực khác trong việc phát triển nội dung cạnh tranh. Châu Á đang trên đà phát triển mạnh mẽ và cần tận dụng xu hướng này để mở rộng thị trường. Đồng thời, các khu vực như Châu Phi, Nam Mỹ và Oceania cần tìm kiếm cách thức để phát triển và quảng bá nội dung của mình, nhằm thu hút khán giả toàn cầu hơn nữa.

2.4. Số lượng phim theo khu vực và thể loại

```
x = np.arange(len(regions)) # Vị trí các cột ghép
width = 0.35 # Độ rộng mỗi cột đơn


fig, ax = plt.subplots(figsize=(15, 6))

# Vẽ cột Movie
bars1 = ax.bar(x - width/2, movie_counts, width, label='Movie', color='skyblue')

# Vẽ cột TV Show
bars2 = ax.bar(x + width/2, tv_show_counts, width, label='TV Show', color='orange')

# Gắn nhãn
ax.set_xlabel('Region')
ax.set_ylabel('Number of Films')
ax.set_title('Number of Films by Region and Type')
ax.set_xticks(x)
ax.set_xticklabels(regions)
ax.legend()
```

Hình 32: Code vẽ biểu đồ Cột đôi thể hiện 2 đạo diễn theo khu vực đứng đầu về số lượng nội dung.



Hình 33: Kết quả biểu đồ Cột đôi thể hiện 2 đạo diễn theo khu vực đứng đầu về số lượng nội dung.

Biểu đồ cột đôi về số lượng phim của các đạo diễn theo từng khu vực cho thấy những điểm nổi bật thú vị. Bắc Mỹ đứng đầu với Jay Karas, người đã sản xuất hơn 14 bộ phim, cho thấy sự vượt trội trong ngành điện ảnh. Ken Burns, với 3 chương trình TV, cũng là một trong những đạo diễn nổi bật trong ngành làm chương trình.

Châu Phi cũng không kém phần ấn tượng khi Cathy Garcia-Molina sản xuất 13 bộ phim, chứng tỏ sự phát triển mạnh mẽ trong lĩnh vực điện ảnh tại đây. Gautham Vasudev Menon với 2 bộ phim phim truyền hình cho thấy rằng tiềm năng lớn cho sự sáng tạo trong

ngành điện ảnh châu Phi.

Châu Âu và Châu Á cũng mang đến những con số đáng chú ý. Youssef Chahine ở châu Âu sản xuất 12 bộ phim, khẳng định vị thế của mình trong nền điện ảnh khu vực. Jan Suter ở châu Á có 9 bộ phim, cho thấy sự đa dạng và phong phú trong sản xuất nội dung tại đây.

Từ những số liệu này, có thể thấy sự chênh lệch rõ rệt về năng suất giữa các đạo diễn trong cùng một khu vực. Bắc Mỹ vẫn giữ vị trí hàng đầu, trong khi châu Phi đang nổi lên với những tài năng sáng tạo. Điều này mở ra cơ hội lớn cho các nhà sản xuất điện ảnh ở châu Phi và những nơi khác, giúp họ phát triển hơn nữa và khai thác tài nguyên sẵn có. Sự phát triển này không chỉ nâng cao chất lượng điện ảnh mà còn mở rộng thị trường cho các sản phẩm từ các khu vực này.

2.5. Đạo diễn với nhiều nội dung nhất theo khu vực


```
x = np.arange(len(regions_sorted)) # Vị trí các cột
width = 0.35 # Độ rộng mỗi cột đơn

fig, ax = plt.subplots(figsize=(15, 6))

# Vẽ cột TV Show
bars = ax.bar(x, tv_show_counts, width, label='TV Show', color='orange')

# Gắn nhãn
ax.set_xlabel('Region')
ax.set_ylabel('Number of TV Shows')
ax.set_title('Number of TV Shows by Region')
ax.set_xticks(x)
ax.set_xticklabels(regions_sorted)
ax.legend()
```

Hình 34: Code vẽ biểu đồ Cột đơn thể hiện đạo diễn theo khu vực đứng đầu về số lượng phim truyền hình.



Hình 35: Kết quả biểu đồ Cột đơn thể hiện đạo diễn theo khu vực đứng đầu về số lượng phim truyền hình.

Biểu đồ cột đơn cho thấy sự khác biệt trong số lượng chương trình truyền hình của các đạo diễn theo khu vực. Châu Âu và Bắc Mỹ có hai đạo diễn nổi bật, mỗi người sản xuất 3 chương trình. Điều này phản ánh sự đầu tư lớn vào nội dung chất lượng cao và khả năng thu hút khán giả của họ, cho thấy sự phát triển mạnh mẽ của ngành công nghiệp truyền hình ở hai khu vực này.

Châu Á, với Gautham Vasudev Menon có 2 chương trình, chứng tỏ xu hướng phát triển tích cực. Ngược lại, châu Phi, châu Đại Dương và Nam Mỹ chỉ có 1 chương trình từ mỗi đạo diễn, cho thấy tiềm năng chưa được khai thác. Sự thiếu hụt này có thể do thiếu đầu tư và cơ sở hạ tầng. Tuy nhiên, đây cũng là cơ hội cho các nhà đầu tư phát triển tài năng địa phương, nâng cao chất lượng nội dung và quảng bá văn hóa của khu vực ra thế giới.

2.6. Đạo diễn sản xuất nhiều bộ phim nhất theo quốc gia


```
# Bước 1: Lọc các Movie
df_movie = dfkhai[dfkhai['type'] == 'Movie']

# Bước 2: Đếm số lượng Movie theo quốc gia
country_counts = df_movie['country'].value_counts().nlargest(6)

# Bước 3: Lấy dữ liệu chi tiết về đạo diễn cho 6 quốc gia hàng đầu, giới hạn 10 đạo diễn cao nhất
subplots_data = {}
for country in country_counts.index:
    country_data = df_movie[df_movie['country'] == country]
    director_counts = country_data['director'].value_counts().nlargest(10) # Giới hạn 10 đạo diễn
    subplots_data[country] = director_counts

# Bước 4: Tạo biểu đồ với make_subplots
fig = make_subplots(
    rows=2, cols=3,
    subplot_titles=country_counts.index,
    horizontal_spacing=0.2, # Giảm khoảng cách ngang giữa các subplot
    vertical_spacing=0.2   # Giảm khoảng cách dọc giữa các subplot
)
```

Hình 36: Mã vẽ biểu đồ Cột đơn thể hiện đạo diễn đứng đầu theo 6 quốc gia về số lượng phim.



Hình 37: Kết quả biểu đồ Cột đơn thể hiện đạo diễn đứng đầu theo 6 quốc gia về số lượng phim.

Các biểu đồ cột đơn cho thấy số lượng phim do các đạo diễn tại từng quốc gia hàng đầu sản xuất, mang lại cái nhìn sâu sắc về ngành công nghiệp điện ảnh toàn cầu.

Tại Hoa Kỳ, dẫn đầu là Jay Karas, tiếp theo là Marcus Raboy và Martin Scorsese. Sự hiện diện của những đạo diễn nổi tiếng này phản ánh sức mạnh của Hollywood và khả năng sản xuất phim lớn, từ đó thu hút khán giả toàn cầu.

Ấn Độ có ba đạo diễn hàng đầu là David Dhawan, Umesh Mehra và Anurag Kashyap. Điều này cho thấy sự phong phú và đa dạng trong nội dung phim Ấn Độ, mang lại nhiều lựa chọn cho khán giả trong nước và quốc tế.

Anh với Edward Cotterill, Tom Hooper và Vince Marcello, thể hiện sự sáng tạo và chất lượng trong phim ảnh. Trong khi đó, Canada (Justin G. Dyck), Pháp (Thierry Donard) và Đức (Detlev Buck) cũng góp mặt mạnh mẽ, chỉ ra sự đa dạng và tiềm năng phát triển trong ngành điện ảnh của từng quốc gia này. Những biểu đồ này không chỉ phản ánh số lượng phim mà còn cho thấy khả năng sáng tạo và đổi mới trong từng nền điện ảnh.

2.7. Diễn viên đóng nhiều bộ phim nhất theo quốc gia


```
def country_trace(country, flag = "movie"):
    df["from_us"] = df['country'].fillna("").apply(lambda x : 1 if country.lower() in x.lower() else 0)
    small = df[df["from_us"] == 1]
    if flag == "movie":
        small = small[small["duration"] != ""]
    else:
        small = small[small["season_count"] != ""]
    cast = ", ".join(small['cast'].fillna("")).split(", ")
    tags = Counter(cast).most_common(25)
    tags = [_ for _ in tags if "" != _[0]]

    labels, values = [_[0]+" " for _ in tags], [_[1] for _ in tags]
    trace = go.Bar(y=labels[::-1], x=values[::-1], orientation="h", name="", marker=dict(color="#a678de"))
    return trace

from plotly.subplots import make_subplots
traces = []
titles = ["United States", "", "India", "", "United Kingdom", "Canada", "", "Spain", "", "Japan"]
for title in titles:
    if title != "":
        traces.append(country_trace(title))

fig = make_subplots(rows=2, cols=5, subplot_titles=titles)
fig.add_trace(traces[0], 1,1)
fig.add_trace(traces[1], 1,3)
fig.add_trace(traces[2], 1,5)
fig.add_trace(traces[3], 2,1)
fig.add_trace(traces[4], 2,3)
fig.add_trace(traces[5], 2,5)
```

Hình 38: Mã vẽ biểu đồ Cột đơn thể hiện diễn viên đứng đầu theo 6 quốc gia về số lượng phim.



Hình 39: Kết quả biểu đồ Cột đơn thể hiện diễn viên đứng đầu theo 6 quốc gia về số lượng phim.


Biểu đồ cột đơn về số lượng phim do các diễn viên tại từng quốc gia hàng đầu sản xuất cho thấy sự phân bố phong phú trong ngành công nghiệp điện ảnh. Tại Hoa Kỳ, Samuel L. Jackson, Tara Strong và Fred Tatasciore là những cái tên nổi bật, thể hiện sức mạnh và tầm ảnh hưởng của Hollywood. Độ đa dạng trong các vai diễn của họ không chỉ thu hút khán giả mà còn làm phong phú thêm nội dung phim.

Ấn Độ với Anupam Kher, Shah Rukh Khan và Naseeruddin Shah chứng tỏ sự phát triển mạnh mẽ của điện ảnh Bollywood. Những nhân vật này không chỉ là biểu tượng của nền điện ảnh Ấn Độ mà còn mang đến nhiều câu chuyện đa dạng, từ tình cảm đến xã hội, thu hút đông đảo người xem cả trong và ngoài nước. Điều này phản ánh tiềm năng lớn của thị trường điện ảnh Ấn Độ.

Ngoài Hoa Kỳ và Ấn Độ, các quốc gia như Anh, Canada, Tây Ban Nha và Nhật Bản cũng có những nhân vật xuất sắc góp mặt trong ngành công nghiệp điện ảnh toàn cầu như David Attenborough, John Cleese và Michael Palin từ Anh; Mario Casas ở Tây Ban Nha hay Takahiro Sakurai và Yuki Kaji ở Nhật Bản làm nổi bật sự đa dạng trong phong cách và chủ đề phim ảnh.

Những thông tin từ biểu đồ này cho thấy rằng sự nổi bật của diễn viên gắn liền với văn hóa và thị trường cụ thể, đồng thời mở ra cơ hội cho sự phát triển của những câu chuyện phong phú và sáng tạo hơn trong ngành công nghiệp điện ảnh toàn cầu.

2.8. Tỷ lệ của từng thể loại phim theo quốc gia



Hình 40: Biểu đồ Heatmap thể hiện tỷ lệ phần trăm loại độ dài phim theo quốc gia

Những bộ phim có độ dài trung bình (từ 60 – 120 phút) hiếm tỷ lệ cao nhất ở hầu hết các quốc gia, dao động từ 74.8% (Anh) đến 86% (Tây Ban Nha). Điều này cho thấy phim trung bình là thể loại phổ biến và được ưa chuộng nhất.

Ấn Độ nổi bật với những bộ phim dài khi thể loại này chiếm 59,3% so với tổng số nội dung trên Netflix. Những bộ phim ngắn (dưới 60 phút) ít được ưa chuộng và xuất hiện hơn trên nền tảng này.

Nhìn chung, biểu đồ phản ánh sự khác biệt trong sở thích và đặc điểm sản xuất phim của từng quốc gia, với sự ưu thế rõ rệt của phim có độ dài trung bình trên toàn cầu.

3. Phân phối theo tính chất và thể loại

3.1. Phân phối thể loại theo Phim và chương trình TV

Đoạn code này thao tác với một DataFrame tên là `country_duration_df`, trong đó chứa thông tin về số lượng phim theo từng quốc gia. Đầu tiên, nó lọc ra dữ liệu của các quốc gia ngoại trừ quốc gia có tên "Unknown" và lấy 10 quốc gia có số lượng phim nhiều nhất. Sau đó, đoạn code tính tỷ lệ phần trăm số lượng phim của từng quốc gia trên tổng số lượng phim của chính quốc gia đó. Kết quả cuối cùng là một DataFrame biểu diễn tỷ lệ phần trăm này, giúp phân tích sự đóng góp của từng quốc gia theo dạng chuẩn hóa.

```
# Giả sử `country_duration_df` là DataFrame chứa số lượng phim
# Lấy top 10 quốc gia có nhiều phim nhất, không lấy "Unknown"
top_countries = country_duration_df.loc[country_duration_df.index != 'Unknown'].head(10)

# Tính tỷ lệ phần trăm theo từng hàng (quốc gia)
percentages = top_countries.div(top_countries.sum(axis=1), axis=0) * 100
```

Hình 41: Chuẩn bị cột để vẽ biểu đồ phân phối thể loại theo phim và chương trình TV


Đoạn mã trên sử dụng thư viện matplotlib và seaborn để vẽ biểu đồ heatmap hiển thị tỷ lệ phần trăm số lượng phim theo thể loại và quốc gia (Top 10).

```
# Vẽ biểu đồ heatmap
import matplotlib.pyplot as plt
import seaborn as sns

plt.figure(figsize=(12, 6))
sns.heatmap(
    percentages,
    cmap='Blues', # Sử dụng bảng màu xanh
    annot=True,
    fmt=".1f",
    cbar_kws={'format': '%.0f%%'}
)
plt.title('Tỷ lệ phần trăm số lượng phim theo thể loại và quốc gia (Top 10)', fontsize=14)
plt.xlabel('Quốc gia', fontsize=12)
plt.ylabel('Thể loại', fontsize=12)

# Hiển thị biểu đồ
plt.tight_layout()
plt.show()
```

Hình 42: Code vẽ biểu đồ Phân phối theo thể loại của phim và chương trình TV



Hình 43: Phân phối theo thể loại của phim và chương trình TV

Biểu đồ phân phối cho thấy sự khác biệt rõ rệt trong phân loại nội dung giữa Movies và TV shows. TV-MA là phân loại phổ biến nhất ở cả hai nhóm, với 1845 tác phẩm thuộc Movies và 1016 thuộc TV Shows, phản ánh sự tập trung lớn vào nội dung dành cho khán giả trưởng thành. Xếp sau đó là TV-14, chủ yếu xuất hiện ở Movies (1272 tác phẩm) so với TV Shows (656 tác phẩm). Một số phân loại như R (663 tác phẩm), PG-13 (386 tác phẩm), và NC-17 chỉ áp dụng cho Movies, trong khi các phân loại như TV-Y, TV-Y7 và TV-G lại xuất hiện riêng ở TV Shows, nhấn mạnh nội dung phù hợp với trẻ em. Các bộ phim có sự đa dạng hơn về phân loại, với trọng tâm vào nội dung trưởng thành (TV-MA, R, PG - 13), trong khi chương trình TV cân bằng hơn giữa nội dung dành cho trẻ em và người lớn. Điều này thể hiện sự khác biệt trong định hướng nội dung của hai hình thức giải trí.

3.2. Tỷ lệ phim theo đối tượng của từng quốc gia

Đoạn code định nghĩa hàm `split_columns` để tách các giá trị trong cột `country` (chứa danh sách các giá trị ngăn cách bởi dấu phẩy) thành các dòng riêng biệt trong DataFrame. Cụ thể, hàm duyệt qua từng dòng, tách cột `country` thành danh sách các giá trị nhỏ, sau đó tạo các dòng mới với mỗi giá trị này cùng dữ liệu từ các cột khác (như `content_type`). Cuối

cùng, nó tạo và trả về một DataFrame mới chứa các dòng đã được tách. Chức năng chính của đoạn code là "phẳng hóa" các danh sách trong cột country để dễ dàng xử lý hoặc phân tích dữ liệu.

```
[ ] def split_columns(df):  
    df = df.copy()  
    new_rows = []  
  
    for index, row in df.iterrows():  
        # Tách các giá trị của director và region  
        country_counts_values = row['country'].split(', ')  
  
        # Duyệt qua tất cả các giá trị của director và region  
        for country in country_counts_values:  
            # Thêm dòng mới vào danh sách, bao gồm type, director, và region  
            new_rows.append([row['content_type'], country])  
  
    # Tạo DataFrame mới từ danh sách các dòng mới  
    df_new = pd.DataFrame(new_rows, columns=df.columns)  
    return df_new
```

Hình 44: Chuẩn bị số liệu để vẽ biểu đồ tỉ lệ phim theo đối tượng của từng quốc gia

Đoạn code này phân tích dữ liệu về số lượng phim theo thể loại và quốc gia, đồng thời trực quan hóa bằng biểu đồ heatmap. Đầu tiên, nó đếm số lượng phim của từng thể loại (content_type) theo quốc gia (country) bằng cách sử dụng groupby và tổ chức kết quả thành bảng với các giá trị 0 cho ô trống. Sau đó, nó tính tổng số lượng phim cho mỗi quốc gia, tính tỷ lệ phần trăm số lượng phim của từng thể loại trên tổng số phim của quốc gia đó. Từ đó, chọn ra 10 quốc gia có tổng số lượng phim lớn nhất, trích lọc dữ liệu liên quan và xoay bảng để các quốc gia thành cột và thể loại thành dòng. Cuối cùng, biểu đồ heatmap được vẽ để minh họa tỷ lệ phần trăm các thể loại phim của 10 quốc gia này, với bảng màu và định dạng trực quan rõ ràng để so sánh dễ dàng.

```
[ ] # Đếm số lượng phim theo thể loại cho từng quốc gia
duration_counts = dfkhai.groupby(['country', 'content_type']).size().unstack(fill_value=0)

# Tính tổng số lượng phim cho mỗi quốc gia
total_counts = duration_counts.sum(axis=1)


# Tính tỷ lệ phần trăm của từng thể loại trên tổng số phim của quốc gia đó
percentage_counts = duration_counts.div(total_counts, axis=0) * 100

# Chọn ra 10 quốc gia có tổng số lượng phim lớn nhất
top_countries = total_counts.sort_values(ascending=False).head(10).index
top_percentage_counts = percentage_counts.loc[top_countries]

# Xoay lại bảng để có 10 cột là quốc gia và 3 dòng là thể loại
top_percentage_counts = top_percentage_counts.T

# Vẽ Heatmap với bảng màu từ đỏ nhạt -> đỏ đậm -> xám tối
plt.figure(figsize=(10, 6)) # Điều chỉnh kích thước để các ô có tỷ lệ vuông
sns.heatmap(top_percentage_counts, annot=True, cmap=cmap, fmt=".1f", cbar=True, linewidths=0.5, square=True)
plt.title("Tỷ lệ phần trăm thể loại phim theo quốc gia")
plt.xlabel("Quốc gia")
plt.ylabel("Thể loại")
plt.show()
```

Hình 45: Code tỉ lệ phần trăm thể loại phim theo quốc gia



Hình 46: Biểu đồ tính tỷ lệ phần trăm thể loại phim theo quốc gia

Biểu đồ thể hiện tỷ lệ nội dung theo độ tuổi mục tiêu tại các quốc gia, nổi bật sự

khác biệt trong định hướng đối tượng của từng quốc gia. Ở Ấn Độ , nội dung chủ yếu nhắm đến đối tượng teens (56%), cao nhất trong tất cả các quốc gia, trong khi nội dung dành cho người trưởng thành chỉ chiếm 26%. Ngược lại, Mexico và Tây Ban Nha có tỷ lệ nội dung dành cho người lớn vượt trội (lần lượt là 76% và 80%), thể hiện sự tập trung lớn vào khán giả trưởng thành. Pháp có tỷ lệ cao nhất về nội dung dành cho kids(15%), trong khi Nhật Bản dẫn đầu về nội dung cho older kids(28%), nhấn mạnh sự quan tâm tới khán giả trẻ. Hàn Quốc có xu hướng cân bằng hơn, nhưng phần lớn nội dung vẫn nhắm vào người lớn (63%). Điều này cho thấy sự khác biệt văn hóa và sở thích của từng quốc gia trong việc sản xuất nội dung giải trí .

3.3. Thể loại

Đoạn mã trên thực hiện việc trích xuất và đếm số lần xuất hiện của các thể loại (genre) từ cột `listed_in` trong dataframe `df`. Đầu tiên, một tập hợp genres được tạo để lưu trữ tất cả các thể loại duy nhất bằng cách duyệt qua các giá trị trong cột `listed_in`, tách từng thể loại dựa trên dấu phẩy, loại bỏ khoảng trắng thừa, và thêm vào tập hợp, đảm bảo mỗi thể loại chỉ xuất hiện một lần. Tiếp theo, một từ điển `genre_count` được khởi tạo để đếm số lần xuất hiện của từng thể loại. Với mỗi giá trị trong cột, các thể loại được tách ra và kiểm tra: nếu đã tồn tại trong từ điển, giá trị tương ứng sẽ được tăng thêm 1; nếu chưa tồn tại, thể loại đó sẽ được thêm vào từ điển với giá trị khởi tạo là 1. Đoạn mã này giúp thu thập thông tin về các thể loại và tần suất của chúng để hỗ trợ phân tích dữ liệu.

```
[ ] # tạo 1 set chứa tất cả các values của column 'listed_in'
genres = set({})
for genre in df['listed_in'].unique():
    for g in genre.split(','):
        genres.add(g.strip())

#count mỗi thể loại xuất hiện bao nhiêu lần
genre_count = {}
for genre in df['listed_in']:
    for g in genre.split(','):
        g = g.strip()
        if g in genre_count:
            genre_count[g] += 1
        else:
            genre_count[g] = 1
```

Hình 47: Code tính số lượng nội dung của mỗi thể loại


Nhóm sắp xếp và lấy top 20 thể loại phim có nhiều nội dung nhất từ `genre_count`, rồi vẽ biểu đồ thanh hiển thị số lượng nội dung cho từng thể loại

```
# vẽ biểu đồ
top_genres = sorted(genre_count.items(), key=lambda x: x[1], reverse=True)[:20]

top_genres = dict(top_genres)

plt.figure(figsize=(12, 6))
sbn.barplot(x=list(top_genres.values()), y=list(top_genres.keys()), color='lightblue')
plt.title('Top 20 thể loại phim có nhiều nội dung nhất')
```


Hình 48: Code vẽ biểu đồ chi tiết về top 20 thể loại phim có nhiều nội dung nhất



Hình 49: Top 20 thể loại phim có nhiều nội dung nhất

Dựa trên biểu đồ thể hiện số lượng nội dung theo thể loại trên Netflix, "International Movies" và "Dramas" là hai thể loại có số lượng nội dung nhiều nhất, với hơn 2.500 nội dung, cho thấy sự ưu tiên đối với phim quốc tế và các bộ phim chính kịch. Các thể loại như "Comedies" "International TV Shows," và "Documentaries" cũng chiếm tỷ lệ lớn, phản ánh sự đa dạng trong thị hiếu người dùng. Đáng chú ý, các thể loại như "Reality TV" và "Stand-Up Comedy" có số lượng ít hơn đáng kể, cho thấy sự tập trung ít hơn vào các nội dung mang tính giải trí ngắn hạn. Điều này giúp xác định hướng phát triển nội dung trên Netflix, với trọng tâm vẫn là các bộ phim và chương trình mang tính nghệ thuật và nội dung sâu sắc.

3.4. Phân phối Châu lục, Thời lượng và Đối tượng Mục tiêu



Hình 50: Biểu đồ Parallel phân phối châu lục, thời lượng và đối tượng mục tiêu

Biểu đồ cho thấy nội dung có thời lượng Trung bình chiếm tỷ lệ lớn nhất, với dòng chảy phù hợp với hầu hết các đối tượng, cũng như đến các khu vực lớn như Châu Mỹ, Châu Á và Châu Âu. Thời lượng dài chủ yếu gắn với nội dung cho người trưởng thành, tập trung tại các khu vực như Châu Á và Châu Mỹ. Trong khi đó, thời lượng ngắn thường liên quan đến nội dung Không được xếp hạng hoặc trẻ vị thành niên, và đa phần xuất phát từ các khu vực ít rõ ràng hoặc Châu Đại Dương.

Nội dung dành cho người trưởng thành nhận dòng chảy lớn nhất từ các thời lượng trung bình và dài, chủ yếu xuất hiện ở các khu vực Châu Mỹ và Châu Á. Phim cho gia đình tuy ít phổ biến hơn nhưng có sự tập trung từ thời lượng Trung bình, đặc biệt tại các khu vực như Châu Âu và Châu Á.

Khu vực Châu Mỹ nhận phần lớn nội dung, đặc biệt là từ thời lượng Trung bình và thể loại Trưởng thành. Châu Á cũng chiếm lượng đáng kể, chủ yếu liên quan đến nội dung Trung bình và dành cho gia đình. Châu Âu có xu hướng nhận nội dung tương tự Châu Á, nhưng ít đa dạng hơn.


3.5. Những chương trình TV có nhiều mùa nhất

Đoạn mã trên thực hiện việc xử lý và trực quan hóa dữ liệu để phân tích các tiêu đề (title) có số mùa nhiều nhất. Đầu tiên, cột `season_count` được tạo mới từ cột `has_seasons`, trong đó các giá trị không chứa cụm "has no season" sẽ được chuyển thành số bằng cách lấy phần đầu tiên của chuỗi, còn các giá trị chứa "has no season" sẽ được gán là None. Sau đó, dữ liệu được sắp xếp theo cột `season_count` giảm dần, và 10 tiêu đề có số mùa cao nhất được chọn để lưu vào dataframe `top_seasons`. Cuối cùng, một biểu đồ thanh ngang được vẽ bằng thư viện Seaborn và Matplotlib để trực quan hóa số lượng mùa của 10 tiêu đề này. Biểu đồ được thiết kế với các thành phần như tiêu đề, nhãn trục x, nhãn trục y, và màu sắc hiển thị, nhằm dễ dàng so sánh số lượng mùa giữa các tiêu đề.

```
[ ] # với column has_seasons, nếu có chứa 'has no season' thì bỏ qua, nếu không thì chuyển thành số và lưu vào cột season_count
df['season_count'] = df['has_seasons'].apply(lambda x: int(x.split()[0]) if 'has no season' not in x else None)

#visualize top 10 title with most seasons, one color, xoay ngang bảng
top_seasons = df.sort_values(by='season_count', ascending=False).head(10)
plt.figure(figsize=(10, 6))
sbn.barplot(x='season_count', y='title', data=top_seasons, color='lightblue')
plt.title('Top 10 show có nhiều mùa nhất')
plt.xlabel('Số mùa')
plt.ylabel('Tựa show')
plt.xticks()
plt.show()
```

Hình 51: Code vẽ biểu đồ các chương trình TV có nhiều mùa nhất



Hình 52: Top 10 chương trình có nhiều mùa nhất

Biểu đồ trên thể hiện top 10 chương trình có số mùa nhiều nhất trên Netflix. Dẫn đầu là "Grey's Anatomy" với hơn 16 mùa, tiếp theo là "NCIS" và "Supernatural" với số mùa gần tương đương. Các chương trình như "Heartland," "COMEDIANS of the world," và "Trailer Park Boys" cũng góp mặt trong danh sách này với số mùa dao động từ 8 đến 10. Những chương trình thuộc nhiều thể loại khác nhau, từ y khoa, hình sự đến hài kịch, thể hiện sự đa dạng về nội dung và sự phổ biến lâu dài của chúng. Biểu đồ nhấn mạnh tầm quan trọng của việc xây dựng nội dung hấp dẫn và duy trì sự yêu thích của khán giả qua nhiều mùa.

CHƯƠNG VI: PHÂN CỤM DỮ LIỆU

1. Tiền xử lý dữ liệu cho phân cụm và xây dựng hệ thống gợi ý

Để thực hiện phân cụm dữ liệu hiệu quả, chúng ta cần chuẩn bị dữ liệu một cách kỹ lưỡng, bao gồm việc tạo các đặc trưng hợp lý từ các thông tin có sẵn trong dataset. Các bước tiền xử lý dưới đây sẽ giúp tạo ra các đặc trưng có ý nghĩa, giúp mô hình phân cụm học được những đặc điểm quan trọng từ dữ liệu. Dưới đây là các bước chi tiết trong quá trình này:

Các đặc trưng này sẽ được nối lại với nhau, mỗi đặc trưng cách nhau bởi dấu cách để tạo ra một chuỗi văn bản duy nhất. Ví dụ, với một bộ phim có đạo diễn là "Steven Spielberg", diễn viên là "Tom Hanks, Meryl Streep", sản xuất tại "United States", thể loại "Drama, History", và mô tả là "A film about war", chuỗi văn bản tạo thành sẽ là: "Steven Spielberg Tom Hanks, Meryl Streep USA Drama, History A film about war".

Bước 1: Nối các đặc trưng thành một đặc trưng duy nhất

Trong bước này, ta sẽ kết hợp một số đặc trưng văn bản quan trọng từ dataset để tạo ra một đặc trưng duy nhất có thể mô tả toàn bộ các yếu tố liên quan đến mỗi bộ phim. Các đặc trưng này bao gồm:

- 'content_type': Loại nội dung của bộ phim.
- 'country': Quốc gia sản xuất bộ phim.
- 'region': Châu lục sản xuất bộ phim.
- 'listed_in': Các thể loại của bộ phim thuộc về.
- 'description': Mô tả về nội dung của bộ phim.

Các đặc trưng này sẽ được nối lại với nhau, mỗi đặc trưng cách nhau bởi dấu cách để tạo ra một chuỗi văn bản duy nhất. Ví dụ, với một bộ phim có đạo diễn là "Steven Spielberg", diễn viên là "Tom Hanks, Meryl Streep", sản xuất tại "United States", thể loại "Drama, History", và mô tả là "A film about war", chuỗi văn bản tạo thành sẽ là: "Steven Spielberg Tom Hanks, Meryl Streep USA Drama, History A film about war".

```
[16] df1['clustering_attributes'] = (df1['content_type'] + ' ' +  
                                   df1['country'] + ' ' +  
                                   df1['region'] + ' ' +  
                                   df1['listed_in'] + ' ' +  
                                   df1['description'])
```

Hình 53: Các đặc trưng được đưa vào mô hình

Bước 2: Xử lý các từ ngữ

- Loại bỏ stopwords: Các từ dừng (stopwords) như "the", "a", "an", "is", "in", v.v. không mang nhiều ý nghĩa trong việc phân tích văn bản, nên chúng sẽ được loại

bỏ. Việc loại bỏ stopwords giúp giảm kích thước của dữ liệu, cải thiện hiệu quả tính toán và đảm bảo các từ quan trọng hơn được chú trọng.

- Chuyển sang chữ thường: Tất cả các chữ cái trong văn bản sẽ được chuyển thành chữ thường để đồng nhất hóa các từ (ví dụ: "Apple" và "apple" sẽ được coi là cùng một từ). Điều này giúp tránh tình trạng phân biệt giữa các từ chỉ khác nhau về chữ hoa và chữ thường.
- Loại bỏ dấu câu: Các dấu câu như dấu phẩy, dấu chấm, dấu chấm hỏi, v.v. không có giá trị trong việc phân tích ngữ nghĩa của văn bản và sẽ bị loại bỏ. Việc này giúp làm sạch văn bản và tập trung vào các từ quan trọng.
- Lemmatization: Lemmatization là quá trình đưa các từ về dạng gốc của chúng. Ví dụ, "running" sẽ được chuyển thành "run", "better" sẽ trở thành "good". Điều này giúp giảm độ phức tạp và giúp mô hình nhận ra rằng các biến thể của một từ vẫn mang cùng một ý nghĩa.

```
def clean_text(text):
    stop_words = set(stopwords.words('english'))
    words = text.lower().split()
    words = [word.lower().translate(str.maketrans('', '', string.punctuation)) for word in words]
    words = [word for word in words if word not in stop_words]
    processed_text = ' '.join(words)
    return processed_text

def lemmatize_verbs(words):
    lemmatizer = WordNetLemmatizer()
    lemmas = []
    for word in words:
        lemma = lemmatizer.lemmatize(word, pos='v')
        lemmas.append(lemma)
    return lemmas
```

Hình 54: Code xử lý các từ ngữ

Bước 3: Loại bỏ các ký tự Non-ASCII

Ở bước này, chúng ta sẽ loại bỏ các ký tự không phải là ASCII. Các ký tự này có thể bao gồm dấu nhấn trong các ngôn ngữ khác hoặc các ký tự đặc biệt không có trong bảng mã ASCII, chẳng hạn như các ký tự Unicode hoặc các ký tự ngoại lai không cần thiết. Ví dụ một trường hợp trong bài là dấu “em dash”, ký hiệu “—” khác với dấu “-”, có mã Unicode là U+2014 nằm ngoài phạm vi của bảng mã ASCII. Việc loại bỏ các ký tự không phải là ASCII giúp chuẩn hóa văn bản, giảm độ phức tạp và tránh các vấn đề không tương thích khi thực hiện các bước tiếp theo như tokenization, vector hóa hoặc phân tích dữ liệu.


```
def remove_non_ascii(words):
    new_words = []
    for word in words:
        new_word = unicodedata.normalize('NFKD', word).encode('ascii', 'ignore').decode('utf-8', 'ignore')
        new_words.append(new_word)
    return new_words
```

Hình 55: Code loại bỏ các ký tự Non_Ascii

Bước 4: Tokenization

Tokenization là quá trình thực hiện việc tách văn bản thành các phần tử nhỏ hơn, trong bối cảnh đề tài này là các từ (tokens). Mỗi token sẽ là một phần được xử lý riêng biệt trong các bước tiếp theo. Việc tokenization giúp chuẩn bị dữ liệu để có thể áp dụng phương pháp TF-IDF (Term Frequency-Inverse Document Frequency).

Trong bước này, mỗi bộ phim sẽ có một tập hợp các từ được tách ra từ chuỗi văn bản, chẳng hạn như:

['kirsten', 'johnson', 'unknown', 'united', 'states', 'documentaries', 'father', 'nears', 'end', 'life', 'filmmaker', 'kirsten', 'johnson', 'stages', 'death', 'inventive', 'comical', 'ways', 'help', 'face', 'inevitable']

```
tokenizer = TweetTokenizer()
df1['clustering_attributes'] = df1['clustering_attributes'].apply(lambda x: tokenizer.tokenize(x))
clustering_data = df1['clustering_attributes']
```

Hình 56: Code Tokenize văn bản

2. Trích xuất đặc trưng văn bản với TF-IDF.

2.1. Lý thuyết về TF-IDF

TF-IDF là một phương pháp thống kê số học giúp phản ánh tầm quan trọng của một từ đối với một tài liệu (document) so với một tập hợp các tài liệu (corpus). Ý tưởng của TF-IDF là định lượng mức độ quan trọng của một từ trong một tài liệu dựa vào tần suất xuất hiện của nó trong một tài liệu và sự hiếm gặp của nó trong các tài liệu khác. Cụ thể hơn giá trị của TF-IDF được tính dựa trên hai yếu tố chính: TF (Term Frequency) và IDF (Inverse Document Frequency).

$$TF(t, d) = \frac{\text{number of times } t \text{ appears in } d}{\text{total number of terms in } d}$$

$$IDF(t) = \log \frac{N}{1 + df}$$

$$TF - IDF(t, d) = TF(t, d) * IDF(t)$$

Hình 57: Công thức TF-IDF

Trong đó:

t: là từ đang xét

d: là tài liệu đang xét (thường là một tài liệu trong corpus).

N: là tổng số lượng tài liệu trong corpus

df: là số lượng tài liệu trong corpus có chứa từ t

Nếu một từ xuất hiện nhiều lần trong tài liệu, giá trị TF của từ đó sẽ tăng lên, từ đó làm tăng giá trị TF-IDF. Điều này có nghĩa là, nếu từ đó đặc trưng cho tài liệu và xuất hiện nhiều lần trong tài liệu, nó có thể quan trọng hơn trong việc phân loại hoặc phân cụm tài liệu. Tuy nhiên, nếu một từ xuất hiện quá nhiều lần trong corpus (tập hợp tài liệu), giá trị IDF của từ đó sẽ giảm xuống. Điều này giúp TF-IDF không bị ảnh hưởng quá mức bởi các từ phổ biến mà thường xuyên xuất hiện trong mọi tài liệu.

2.2. Thực nghiệm trích xuất đặc trưng với Python

Để tiến hành phân cụm văn bản, việc mã hóa các văn bản thành các vector đặc trưng số học mà máy tính có thể hiểu và xử lý vô cùng quan trọng. Trong quá trình này, nhóm sử dụng `TfidfVectorizer` từ thư viện `sklearn` để chuyển đổi đặc trưng 'clustering_data' thành ma trận đặc trưng TF-IDF mà mô hình phân cụm có thể xử lý. Và do tài nguyên của nhóm có hạn nên `max_features=20000` được truyền vào đối số của `TfidfVectorizer`. Tham số này sẽ giới hạn số lượng đặc trưng tối đa được sử dụng trong ma trận TF-IDF.

Quá trình này tạo ra một ma trận TF-IDF trong đó mỗi dòng tương ứng với một tài liệu, và mỗi cột tương ứng với một từ vựng trong tập dữ liệu đã được chọn. Mỗi phần tử trong ma trận là giá trị TF-IDF của từ đó trong dòng tương ứng. Ma trận này sẽ được sử dụng làm đặc trưng đầu vào cho các thuật toán phân cụm, giúp nhóm các tài liệu tương tự vào cùng một cụm.

```
def identity_tokenizer(text):
    return text

tfidf = TfidfVectorizer(tokenizer=identity_tokenizer, max_features = 20000)
X = tfidf.fit_transform(clustering_data)

[23] X.shape

(8790, 20639)
```

Hình 58: Trích xuất đặc trưng

Kết quả sau khi trích xuất đặc trưng thu được một ma trận với 8790 vector, trong đó mỗi vector có kích thước 20639.

3. Áp dụng PCA giảm chiều dữ liệu

3.1. Lý thuyết về PCA

PCA (Principal Component Analysis) là một phương pháp giúp giảm số lượng đặc trưng (features) trong dữ liệu, trong khi vẫn giữ lại phần lớn thông tin quan trọng. Khi bộ dữ liệu có rất nhiều đặc trưng điều này khiến cho việc phân tích và trực quan hóa trở nên khó khăn. PCA sẽ giúp giảm số lượng đặc trưng, cố gắng giữ lại các đặc trưng quan trọng đóng góp nhiều phương sai nhất để không làm mất quá nhiều thông tin, giúp dữ liệu trở nên dễ hiểu và dễ phân tích hơn.

Các thuộc tính mô tả phương sai lớn nhất được gọi là các thành phần chính (Principal components). Thành phần chính đầu tiên, tức thành phần đóng góp nhiều phương sai nhất sẽ được đặt tại tọa độ đầu tiên. Tương tự như vậy, thuộc tính đứng thứ hai trong việc mô tả phương sai được gọi là thành phần chính thứ hai. Thông thường, hơn 90% phương sai được giải thích bởi hai hay ba thành phần chính.

Các bước thực hiện PCA:

Bước 1: Chuẩn bị ma trận X cần giảm chiều có kích thước (m x n). Với m là số mẫu (số dòng) và n là số đặc trưng (số cột) của dữ liệu.

Bước 2: Tính trung bình các phần tử của mỗi cột để có được tọa độ vector trọng tâm.

$$M = \text{mean}(A)$$

Bước 3: Từ tọa độ của vector trọng tâm có được, tính tọa độ mới của các phần tử trong ma trận X sau khi dời gốc tọa độ ban đầu thành tọa độ vector trọng tâm.

$$\hat{X} = A - M$$

Bước 4: Tìm ma trận hiệp phương sai V của ma trận X sau khi dời gốc tọa độ.

$$V = \text{Covariance}(\hat{X})$$

Bước 5: Tìm các trị riêng (eigenvalues) và các vector riêng (eigenvector). Ở bước này có

thể loại các trị riêng nào có giá trị nhỏ hơn hẳn so với các trị riêng khác.

$$Y, U = \text{Eigen}(V)$$

Bước 6: Tạo ma trận B là tổ hợp các vector riêng ở bước 5 khi ghép lại.

$$B = \text{Columns}(U, 1:k)$$

Bước 7: Tính tọa độ mới của các phần tử trong không gian chỉ có k chiều.

$$\hat{A} = B^T \cdot A$$

3.2. Tiến hành thực nghiệm giảm chiều dữ liệu với PCA trên Python.

Đầu tiên, xác định ngưỡng phương sai tích lũy (threshold) muốn giữ lại là 90%. Tiếp theo, chúng ta khai báo đối tượng PCA với tham số ngưỡng phương sai tích lũy (threshold) đã xác định trước đó. Tham số này sẽ giúp PCA tính toán số lượng thành phần chính tối thiểu cần thiết để giữ lại ít nhất 90% phương sai tích lũy. Sau khi thực hiện PCA, có được số lượng thành phần chính cần thiết là k và phương sai tích lũy tương ứng với những thành phần đó. Các giá trị này được truy xuất thông qua các thuộc tính của đối tượng PCA.

Với `pca.n_components_`: Đây là thuộc tính cho biết số lượng thành phần chính cần thiết để bảo toàn ít nhất 90% phương sai tích lũy. Và `pca.explained_variance_ratio_`: Đây là mảng chứa tỷ lệ phương sai mà mỗi thành phần chính giải thích được. Ta có thể tính tổng các giá trị trong mảng này để biết được phương sai tích lũy.

```
[ ] threshold = .90
    percent   = threshold * 100

    pca = PCA(threshold)
    pca.fit_transform(X)

    k    = pca.n_components_
    var  = sum(pca.explained_variance_ratio_) * 100
    print('Phương sai tích lũy >= %.1f%%' %percent, 'khi k >= %d' %k)
```

Hình 59: Code thực nghiệm PCA

Kết quả thu được với số lượng thành phần chính $k \geq 4907$ sẽ giữ lại được 90% lượng phương sai tích lũy. Tiến hành thực hiện lại PCA với k tìm được và lưu lại kết quả vào tệp “x_pca4907.parquet” (Nhóm dùng định dạng tệp parquet nhằm giảm bộ nhớ khi lưu trữ kết quả thay cho định dạng csv).

```
pca = PCA(n_components=k, random_state=42)
pca.fit(X)
```

```
x_pca = pca.transform(X)
x_pca.shape
x_pca_df = pd.DataFrame(x_pca)
x_pca_df.to_parquet('/content/gdrive/MyDrive/DaVi/x_pca4907.parquet')

(8790, 4907)
```

Hình 60: Kết quả PCA

Tóm lại, sau khi thực hiện giảm chiều dữ liệu bằng phương pháp PCA, nhóm đã thành công trong việc giảm kích thước của vector từ 20639 xuống còn 4907.

4. Phân cụm K-means

4.1. Học máy không giám sát

Unsupervised Learning là học không giám sát vì chúng ta không biết được đầu ra (outcome hay nhãn) trông như thế nào mà chỉ có dữ liệu đầu vào. Thuật toán unsupervised learning sẽ dựa vào cấu trúc của dữ liệu để thực hiện một công việc nào đó, ví dụ như phân cụm (clustering) hoặc giảm số chiều của dữ liệu (dimension reduction) để thuận tiện trong việc lưu trữ và tính toán. Hiểu theo một cách khác, Unsupervised learning là khi chúng ta chỉ có dữ liệu đầu vào X mà không biết nhãn Y tương ứng. Những thuật toán loại này được gọi là Unsupervised learning vì không giống như Supervised learning, chúng ta không biết câu trả lời chính xác cho mỗi dữ liệu đầu vào. Cụm không giám sát được đặt tên theo nghĩa này.

Một trong những bài toán cụ thể của Unsupervised learning chính là Clustering (phân cụm). Clustering là một bài toán phân cụm toàn bộ dữ liệu X thành các cụm nhỏ dựa trên sự liên quan giữa các dữ liệu trong mỗi nhóm. Ví dụ: phân cụm khách hàng dựa trên hành vi mua hàng. Điều này cũng giống như việc đưa cho một đứa trẻ rất nhiều mảnh ghép với các hình thù và màu sắc khác nhau, ví dụ tam giác, vuông, tròn với màu xanh và đỏ, sau đó yêu cầu trẻ phân chúng thành từng nhóm. Mặc dù không cho trẻ biết mảnh nào tương ứng với hình nào hoặc màu nào, nhiều khả năng chúng vẫn có thể phân loại các mảnh ghép theo màu hoặc hình dạng.

4.2. Thuật toán phân cụm K-means

Thuật toán K-means clustering (phân cụm K-means) chính là một trong những thuật toán cơ bản nhất trong Unsupervised learning. Trong thuật toán K-means clustering, chúng ta không biết nhãn (label) của từng điểm dữ liệu. Mục đích là làm thế nào để phân dữ liệu thành các cụm (cluster) khác nhau sao cho dữ liệu trong cùng một cụm có tính chất giống nhau.

Đối với thuật toán K-Means Clustering, mỗi cụm dữ liệu được đặc trưng bởi một trọng tâm (centroid). Trọng tâm của cụm được xác định bởi trung bình của tọa độ toàn bộ các điểm dữ liệu nằm trong cụm. Nhãn của mỗi điểm sẽ được xác định bởi trọng tâm có khoảng cách Euclidean gần nhất đến quan sát đó.

Cụ thể hơn thuật toán K-Means hoạt động như sau:

- Bước 1: Khởi tạo ngẫu nhiên k trọng tâm $\{u_1, u_2, u_3, \dots\}$
- Bước 2: Với mọi điểm dữ liệu sẽ được gán nhãn theo trọng tâm gần nhất. Trong đó, khoảng cách từ điểm dữ liệu đến trọng tâm sẽ được tính bằng khoảng cách Euclid.
- Bước 3: Cập nhật tọa độ của các trọng tâm mới bằng cách tính trung bình tọa độ của các điểm dữ liệu trong cụm tương ứng.
- Bước 4: Lặp lại bước 2 cho đến khi nhãn của các điểm dữ liệu không thay đổi nữa thì thuật toán kết thúc.

4.3. Thực hiện thuật toán KMeans-Clustering trên Python

Sau khi tìm hiểu về thuật toán phân cụm K-Means, nhóm tiến hành áp dụng thuật toán này để phân cụm các thuộc tính đã chọn, bao gồm 'listed_in', 'region', 'country', 'description' và 'content_type'. Các thuộc tính này đã được tiền xử lý và trích xuất đặc trưng dưới dạng vector thông qua phương pháp TF-IDF. Để giảm kích thước của các vector, tối ưu lượng tài nguyên tiêu tốn và tăng hiệu quả huấn luyện, nhóm cũng sử dụng phương pháp PCA (Principal Component Analysis) để thực hiện giảm chiều dữ liệu.


Mục tiêu của quá trình này là khai thác các thông tin ẩn sâu bên trong bộ dữ liệu mà chưa được phát hiện, giúp việc phân tích và gợi ý trở nên chính xác hơn. Nhóm tiến hành xây dựng và huấn luyện mô hình phân cụm K-Means trên Python, sử dụng thư viện sklearn với thuật toán KMeans đã được tích hợp sẵn.

Để xác định số lượng cụm k thích hợp, nhóm thử nghiệm với các giá trị k trong khoảng từ 2 đến 15 và đánh giá kết quả phân cụm dựa trên chỉ số Silhouette score.

```
[ ] range_n_clusters = range(2,15)
    silhouette_avg = []
    for num_clusters in range_n_clusters:
        kmeans = KMeans(n_clusters=num_clusters,init='k-means++',random_state=33)
        kmeans.fit(x_pca)
        cluster_labels = kmeans.labels_
        silhouette_avg.append(silhouette_score(x_pca, cluster_labels))

    plt.figure(figsize=(10,5))
    plt.plot(range_n_clusters,silhouette_avg)
    plt.xlabel('Giá trị K')
    plt.ylabel('Silhouette score')
    plt.title('Tối ưu K dựa vào Silhouette score - KMeans Clustering')
    plt.show()
```

Hình 61: Thực hiện thuật toán Phân cụm Kmeans



Hình 62: Chỉ số Silhouette

Sau quá trình thử nghiệm, kết quả cho thấy $k = 7$ đạt được chỉ số Silhouette cao nhất là 0.0114 trong khoảng thử nghiệm (2, 15). Vì vậy, nhóm quyết định chọn $k = 7$ làm số lượng cụm và thực hiện khởi tạo mô hình K-Means với $k = 7$.


Sau khi phân cụm xong, nhóm thêm một cột mới vào dataframe có tên 'kmeans_cluster', lưu trữ nhãn phân cụm tương ứng với mỗi dòng của bộ dữ liệu.

```
[ ] kmeans = KMeans(n_clusters=7,init='k-means++',random_state=42)
    kmeans.fit(x_pca)
    kmeans_silhouette_score = silhouette_score(x_pca, kmeans.labels_)
    print(kmeans_silhouette_score)
    df1['kmeans_cluster'] = kmeans.labels_
```

Hình 63: Thêm cột kmeans_cluster vào bộ dữ liệu


5. Phân tích kết quả sau khi phân cụm với KMeans

5.1. Tổng quan kết quả phân cụm




Hình 64: Sự khác biệt của content_type theo từng cụm

Nhìn chung, hai cụm có nhiều nội dung nhất là cụm 1 và cụm 5, cụm có số lượng nội dung ít nhất là cụm 6. Hầu hết các cụm đều có nội dung dành cho người trưởng thành chiếm phần lớn, riêng cụm 4 có nội dung phù hợp với gia đình và trẻ em, cụm 3 có các nội dung phù hợp với trẻ vị thành niên chiếm đa số. Ở cụm 6, nội dung hầu hết chỉ dành cho người trưởng thành.




Hình 65: Số lượng nội dung có trong từng cụm



Hình 66: Số lượng các chương trình TV và Movie theo cụm


5.2. Phân tích cụm 0



Hình 67: Top 10 quốc gia có số lượng show cao nhất trong cụm 0

Trong cụm trên, Hoa Kỳ dẫn đầu với số lượng phim vượt trội so với các quốc gia khác khi có tới 441 nội dung trên nền tảng này, chiếm hơn 50% so với tổng số nội dung trong cụm. Theo sau đó là các quốc gia Ấn độ và Anh với số lượng show chênh lệch lớn, đạt lần lượt là 135 và 80 nội dung.

Những quốc gia có số nội dung đóng góp thấp hơn bao gồm: Hàn Quốc, Đức, Pháp, Canada. Những quốc gia này có số lượng nội dung xuất hiện từ 17 - 50 lượt, tổng số lượng đóng góp chỉ bằng $\frac{1}{3}$ so với Hoa Kỳ.




Hình 68: Số lượng nội dung theo thể loại trong cụm 0

Đối tượng chính của cụm phim này là người trưởng thành và trẻ vị thành niên khi những nội dung dành cho 2 đối tượng này chiếm hơn 87% so với tổng thể. Đây không phải cụm phim phù hợp để đề xuất những bộ phim dành cho trẻ em hoặc gia đình.

hộp và phiếu lưu.


5.3. Phân tích cụm 1



Hình 70: Biểu đồ cột đơn Top 10 quốc gia có số lượng show cao nhất trong cụm 1

Tương tự như cụm 0, Hoa Kỳ vẫn là quốc gia có nhiều đóng góp vào cụm nhất với 2666 nội dung, chiếm 92% so với tổng thể. Những quốc gia xếp thứ 2 và thứ 3 có sự thay đổi là Canada và Mexico. Có thể thấy, 3 quốc gia hàng đầu trong cụm này đều đến từ khu vực Châu Mỹ.


Những quốc gia có xuất hiện với tần suất ít hơn bao gồm Trung Quốc, Úc và Ấn Độ.



Hình 71: Số lượng nội dung theo thể loại trong cụm 1

Như đã dự đoán ở phần thể loại, đối tượng phù hợp với cụm 1 khá đa dạng và đồng đều. Nội dung dành cho người trưởng thành vẫn chiếm một số lượng tương đối lớn, tuy nhiên, nội dung dành cho Trẻ em và gia đình cũng xếp thứ 2 và chiếm đến 31,5% so với tổng thể.

Cụm phim này cũng có nhiều nội dung phù hợp cho đối tượng trẻ vị thành niên. Nhìn chung, đây là một cụm phim có thể tiếp cận được với nhiều đối tượng.




Hình 72: Thể loại và từ khóa xuất hiện nhiều trong cụm 1

Biểu đồ trên thể hiện rằng Dramas là thể loại phổ biến nhất với 701 lần xuất hiện, phản ánh cụm này tập trung vào các câu chuyện giàu cảm xúc, nội dung sâu sắc và có chiều sâu. Thể loại Comedies đứng thứ hai với 608 lần xuất hiện, cho thấy sự cân bằng giữa nội dung cảm xúc và giải trí nhẹ nhàng. Bên cạnh đó, thể loại Documentaries (495) xuất hiện nhiều, cho thấy cụm này không chỉ tập trung vào nội dung giải trí mà còn cung cấp thông tin, giáo dục, thể loại Children & Family Movies (363) và Independent Movies (355) chỉ ra rằng nội dung trong cụm này có tính đa dạng cao, phù hợp với cả đối tượng gia đình và những khán giả yêu thích các tác phẩm nghệ thuật độc lập. Ngoài ra, thể loại Thrillers (255) và TV Comedies (222) thể hiện sự hiện diện của yếu tố hồi hộp và hài hước, phục vụ các sở thích khác nhau của người dùng.

Word Cloud của cụm 1 cho thấy "life," "new," "find," "family," "friend" là những từ xuất hiện lớn nhất, chỉ ra rằng nội dung trong cụm này tập trung nhiều vào các chủ đề nhân văn như cuộc sống, gia đình, tình bạn và hành trình khám phá bản thân. Những từ như "father," "daughter," "son," "love," "bond" cho thấy sự nhấn mạnh vào các câu chuyện gia đình và mối quan hệ cá nhân. Ngoài ra, Word Cloud còn xuất hiện các từ khóa như "discover," "dream," "begin," "save" thể hiện nội dung liên quan đến hành trình, khám phá và xây dựng tương lai, các từ như "documentary," "career," "school," "series" chỉ ra sự hiện diện của nội dung giáo dục, sự nghiệp và câu chuyện học đường và yếu tố hồi hộp, bí ẩn còn được thể hiện qua các từ như "secret," "murder," "crime"


Tổng quan, cụm 1 nhấn mạnh vào nội dung giàu cảm xúc, có chiều sâu và đa dạng, phù hợp với nhiều nhóm khán giả, từ gia đình, trẻ em, đến những người yêu thích phim tài liệu và nội dung hài hước.

5.4. Phân tích cụm 2




Hình 73: Biểu đồ cột đơn Top 10 quốc gia có số lượng show cao nhất trong cụm 2.

Biểu đồ cho thấy cụm 2 có 560 show từ Vương Quốc Anh, chiếm tỷ lệ vượt trội so với các quốc gia khác. Vương Quốc Anh dẫn đầu cụm này cho thấy sự đóng góp quan trọng từ các chương trình sản xuất thuộc quốc gia này. Quốc gia xếp thứ hai là Hoa Kỳ với 124 show chỉ bằng khoảng 22% số lượng show của Vương Quốc Anh, tuy có số lượng show lớn nhưng vẫn không nổi bật bằng Vương Quốc Anh. Các quốc gia còn lại trong top 10 bao gồm Ireland, Japan, Australia, Belgium, Spain, Canada, Germany, và France có số lượng show rất thấp, dao động từ 7 đến 29 show. Tổng số lượng show của 8 quốc gia này cộng lại vẫn ít hơn số lượng show của Hoa Kỳ, phản ánh rằng cụm 2 có sự tập trung cao độ vào nội dung từ Anh và phần nào từ Mỹ.



Hình 74: Biểu đồ cột đơn thể hiện số lượng thể loại trong cụm 2.

Từ biểu đồ ta thấy rằng, thể loại "Adult" chiếm tỷ lệ lớn nhất trong cụm 2 với số lượng là 272, phản ánh sự ưu tiên cho nội dung trưởng thành trong nhóm dữ liệu này. Các nội dung này có thể bao gồm các bộ phim hoặc chương trình tập trung vào các khía cạnh phức tạp, sâu sắc hoặc kịch tính hơn. Xếp thứ hai là nội dung dành cho gia đình (Family: 164), cho thấy Netflix vẫn có sự quan tâm đến đối tượng khán giả gia đình trong cụm này. Nội dung dành cho tuổi teen xếp thứ ba trong cụm, nhấn mạnh sự cân bằng trong việc phục vụ các nhóm khán giả trẻ tuổi. Nhìn chung, cụm 2 tập trung chủ yếu vào nội dung trưởng thành và gia đình, cho thấy các show ở cụm này nhắm đến đa dạng đối tượng khán giả nhưng ưu tiên khán giả trưởng thành hơn.




Hình 75: Thể loại và từ khóa xuất hiện nhiều trong cụm 2

Từ kết quả này thể hiện rằng thể loại British TV Shows dẫn đầu với 220 lần xuất hiện, phản ánh sự tập trung cao vào các chương trình truyền hình đến từ Anh. Thể loại International TV Shows (128) và Dramas (123) cũng rất phổ biến, cho thấy cụm này không chỉ tập trung vào nội dung địa phương mà còn mang tính toàn cầu và giàu cảm xúc. Bên cạnh đó, sự xuất hiện của thể loại International Movies (112) và Documentaries (103) cho thấy cụm này còn cung cấp nội dung đa dạng, bao gồm các bộ phim và tài liệu từ nhiều quốc gia, 2 thể loại Docuseries (84) và Comedies (56) trong cụm cũng thể hiện sự cân bằng giữa nội dung cung cấp thông tin và giải trí. Ngoài ra, các thể loại như Crime TV Shows (50), Independent Movies (48), và TV Comedies (44) có tần suất thấp hơn nhưng vẫn góp phần tạo nên sự phong phú cho nội dung của cụm này.

Word Cloud trên xuất hiện các từ "new," "life," "world," "series" là những từ xuất hiện lớn nhất, nhấn mạnh các chủ đề liên quan đến cuộc sống, sự đổi mới, và sự khám phá thế giới. Các từ như "documentary" và "explore" cũng chỉ ra tầm quan trọng của các nội dung về tài liệu và liên quan đến hành trình khám phá. Từ như "love," "save," "journey" nhấn mạnh các yếu tố tình cảm, bảo vệ và hành trình, cho thấy sự phong phú về cảm xúc trong nội dung. Ngoài ra, "british," "london," "england" là những từ xuất hiện nổi bật, củng cố vai trò trung tâm của các chương trình và phim ảnh có xuất xứ từ Anh, các từ như "crime," "investigate," "murder," "dark" cũng cho thấy sự hiện diện của các nội dung kịch tính và bí ẩn.

Tổng quan, cụm 2 có sự nổi bật từ các chương trình truyền hình đến từ Anh và quốc tế, nhấn mạnh vào yếu tố đặc trưng văn hóa và cảm xúc phong phú. Nội dung trong cụm này đa dạng, từ tài liệu khám phá đến các bộ phim giàu cảm xúc, phù hợp với những khán giả yêu thích các chủ đề khám phá, câu chuyện nhân văn, và yếu tố bí ẩn.

5.5. Phân tích cụm 3



Hình 76: Biểu đồ cột đơn thể hiện số lượng thể loại trong cụm 3.

Số lượng lớn nhất của cụm 3 thuộc thể loại dành cho tuổi teen (Teen: 613), thể hiện sự tập trung mạnh mẽ vào khán giả trẻ tuổi trong cụm này. Các chương trình này có thể mang tính giải trí, nhẹ nhàng và phù hợp với lứa tuổi. Nội dung trưởng thành (Adult: 365) vẫn chiếm một tỷ lệ đáng kể, cho thấy cụm này không chỉ nhắm đến khán giả trẻ mà còn phục vụ một phần lớn khán giả trưởng thành. Nội dung gia đình xếp thứ ba trong cụm, phản ánh mối quan tâm đến đối tượng xem chung trong gia đình. Nhìn chung, cụm 3 có sự tập trung lớn vào nội dung tuổi teen và trưởng thành, thể hiện nỗ lực đa dạng hóa để thu hút cả khán giả trẻ tuổi lẫn người lớn, trong khi nội dung gia đình vẫn được duy trì ở mức đáng kể.

Từ kết quả trên, ta thấy Ấn Độ dẫn đầu cụm 3 với 870 show, chiếm phần lớn tổng số show trong cụm, phản ánh sự phát triển mạnh mẽ của ngành công nghiệp Bollywood và các nội


$$3.1 \times 10^{-2} \leq \frac{N}{\mu} \leq 1.1 \times 10^{-1} \quad \text{and} \quad 1.35 \times 10^{-1} \leq \frac{1}{\mu} \leq 1.6 \times 10^{-1}$$


Word Cloud của cụm 3 cho thấy rằng các từ như "family," "love," "life," "man,"

77

đình, tình yêu, cuộc sống, và mối quan hệ cá nhân. Các từ như "friend," "couple," "husband," "wife" cho thấy sự đa dạng trong việc khai thác các mối quan hệ xã hội, từ tình bạn đến hôn nhân. Từ như "dream," "find," "new" xuất hiện nhấn mạnh các yếu tố liên quan đến khát vọng và sự thay đổi trong cuộc sống. Sự xuất hiện của từ "india" và các từ liên quan có thể cho thấy một lượng lớn nội dung đến từ khu vực này, phù hợp với vị trí dẫn đầu của các bộ phim quốc tế.

Tổng quan, cụm 3 tập trung vào các thể loại mang tính toàn cầu như phim quốc tế và phim kịch tính, nhưng cũng bao gồm nội dung lãng mạn và hài hước. Các từ khóa nổi bật nhấn mạnh chủ đề về gia đình, tình yêu, và mối quan hệ xã hội, cho thấy nội dung trong cụm này thiên về cảm xúc và nhân văn. Nội dung từ Ấn Độ và các quốc gia quốc tế đóng vai trò quan trọng trong cụm, giúp thu hút đối tượng khán giả toàn cầu.

5.6. Phân tích cụm 4



Hình 78: Số lượng nội dung theo thể loại trong cụm 4


Dựa vào biểu đồ cột, cụm 4 có số lượng lớn nhất thuộc thể loại nội dung dành cho gia đình (Family) với 303 chương trình, cho thấy sự tập trung mạnh mẽ vào các nội dung phù hợp cho việc xem chung trong gia đình. Thể loại nội dung dành cho người trưởng thành (Adult) đứng thứ hai với 261 chương trình, phản ánh sự quan tâm đến các đối tượng khán giả trưởng thành. Nội dung dành cho tuổi teen (Teen) có số lượng 235 chương trình, thể hiện mức độ quan tâm đến đối tượng trẻ tuổi, nhưng không phải là trọng tâm chính của

[illegible]

Biểu đồ trên chỉ ra rằng thể loại International TV Shows chiếm vị trí dẫn đầu với 224 lần xuất hiện, cho thấy nội dung truyền hình quốc tế là trọng tâm trong cụm này, phù hợp với xu hướng thu hút khán giả toàn cầu. Thể loại International Movies (210) đứng thứ hai, phản ánh sự đa dạng về nội dung phim quốc tế. Các thể loại phổ biến khác như Dramas (111), Children & Family Movies (106), và TV Dramas (101) nhấn mạnh nội dung xoay quanh các chủ đề kịch tính, cảm xúc, và phù hợp với đối tượng gia đình, thể loại Comedies (94) và Kids' TV (80) cũng bổ sung thêm yếu tố giải trí và sự hấp dẫn đối với trẻ em. Các thể loại ít phổ biến hơn như TV Comedies (78), Documentaries (75), và Romantic TV Shows (71) có tần suất thấp hơn nhưng vẫn đóng góp vào sự đa dạng nội dung của cụm.

Tổng quan, cụm 4 tập trung vào các thể loại truyền hình quốc tế, phim quốc tế và nội dung dành riêng cho gia đình và trẻ em, có thể xác định mục tiêu hướng tới chân giả toàn cầu và nhiều tuổi. Các từ khóa nổi bật xung quanh chủ đề gia đình, tình yêu, và cuộc sống, tạo nên sự cân bằng giữa nội dung giải trí và cảm xúc.


5.7. Phân tích cụm 5



Hình 80: Biểu đồ cột đơn Top 10 quốc gia có số lượng show cao nhất trong cụm 5


Biểu đồ cho thấy sự đa dạng về nguồn gốc của các chương trình trong cụm 5, với Pháp dẫn đầu về số lượng. Sự cạnh tranh giữa Pháp và Hàn Quốc, hai quốc gia có số lượng chương trình vượt trội, là rất đáng chú ý. Tuy nhiên, sự phân bố không đồng đều giữa các quốc gia cũng cho thấy những cơ hội để phát triển và mở rộng quy mô của cụm 5 trong

tương lai



Hình 81: Số lượng nội dung theo thể loại trong cụm 5


Biểu đồ cho thấy một bức tranh khá rõ ràng về sự thống trị của thể loại "Adult" trong cụm 5. Điều này phần nào phản ánh nhu cầu của một bộ phận khán giả lớn. Tuy nhiên, tiềm năng phát triển của các thể loại như "Teen" và "Family" cũng rất đáng chú ý. Để khai thác tối đa tiềm năng này, các nhà sản xuất nội dung cần tập trung vào việc tạo ra những sản phẩm chất lượng cao, phù hợp với sở thích của từng đối tượng khán giả. Đồng thời, việc cải thiện hệ thống phân loại nội dung sẽ giúp tạo ra một môi trường sáng tạo và



Word Cloud cho thấy các từ như "young," "family," "love," "man," "woman" xuất hiện nổi bật, nhấn mạnh sự tập trung vào các chủ đề về gia đình, tình yêu, và mối quan hệ cá nhân. Từ "find," "new," "world," và "live" cho thấy các yếu tố khám phá, đổi mới, và trải nghiệm cuộc sống, phản ánh sự phong phú trong nội dung. Các từ như "teen," "mysterious," và "crime" làm nổi bật sự xuất hiện của các nội dung liên quan đến tuổi trẻ, bí ẩn, và tội phạm. Sự kết hợp của các từ "father," "mother," "group," và "adventure" chỉ ra các cốt truyện đa dạng, từ hành trình gia đình đến các mối quan hệ xã hội.

83

5.8. Phân tích cụm 6




Hình 83: Biểu đồ cột đơn Top 10 quốc gia có số lượng show cao nhất trong cụm 6

Kết quả phân cụm dữ liệu cho cụm 6 cho thấy sự chênh lệch rõ rệt về số lượng show giữa các quốc gia. Trong khi Hoa Kỳ dẫn đầu với 251 show duy nhất, các quốc gia khác chỉ đóng góp một phần nhỏ vào tổng số này. Cụ thể, các quốc gia như Colombia, Germany và France chỉ có lần lượt 4, 5 và 6 show, cho thấy sự tập trung mạnh mẽ của hoạt động


biểu diễn tại Mỹ.

Một điểm đáng chú ý khác là sự hiện diện của các quốc gia như Mexico và Vương quốc Anh, mỗi nước có 19 show duy nhất. Điều này cho thấy rằng không chỉ Hoa Kỳ mà một số nước khác cũng có sự đóng góp đáng kể vào cụm 6, mặc dù vẫn còn kém xa so với Mỹ. Sự hiện diện của nhóm "Không xác định" với 32 show cũng chỉ ra rằng có thể có các nội dung chưa được phân định quốc gia rõ ràng, cho thấy tiềm năng cho nghiên cứu sâu hơn.



Hình 84: Biểu đồ cột đơn Số lượng thể loại nội dung trong cụm 6

Thể loại Teen với 35 show cũng cho thấy sự quan tâm đến đối tượng thanh thiếu niên, mặc dù số lượng này vẫn còn thấp. Trong khi đó, thể loại Family chỉ ghi nhận 12 show, cho thấy rằng nội dung giải trí phù hợp cho cả gia đình chưa được phát triển mạnh mẽ.




Word Cloud cho thấy các từ như "comedian," "standup," "special," và "comic" nổi bật nhất, nhấn mạnh sự chú trọng vào các chương trình hài độc thoại và những buổi biểu diễn đặc biệt. Các từ như "life," "stories," "joke," và "humor" phản ánh nội dung xoay quanh các câu chuyện đời sống, yếu tố hài hước, và những màn trình diễn giàu cảm xúc. Từ "live" và "stage" làm nổi bật tính trực tiếp và biểu diễn sân khấu, vốn là đặc trưng của thể loại này. Ngoài ra, các từ như "sex," "relationships," và "celebrity" cho thấy nội dung còn khai thác những chủ đề xã hội và các mối quan hệ, giúp tăng sự hấp dẫn đối với khán giả. Tổng quan, cụm 6 tập trung mạnh vào các nội dung hài độc thoại và các chương trình giải trí hài hước, với các chủ đề đời sống và xã hội, mang lại sự hấp dẫn đa dạng cho khán giả yêu thích sự hài hước và nghệ thuật biểu diễn.

CHƯƠNG VII: XÂY DỰNG RECOMMEND SYSTEM.

1. Khái niệm về Recommend System

Hệ thống gợi ý (Recommend System) là một thuật toán trí tuệ nhân tạo (AI), thường liên quan đến học máy, sử dụng Big data để gợi ý hoặc đề xuất các sản phẩm tương tự cho người tiêu dùng. Các gợi ý này có thể dựa trên nhiều tiêu chí khác nhau, bao gồm các lần mua trước, lịch sử tìm kiếm, thông tin nhân khẩu học, các đặc trưng của sản phẩm và các yếu tố khác. Hệ thống gợi ý rất hữu ích vì chúng giúp người dùng khám phá những sản phẩm và dịch vụ phù hợp với nhu cầu của họ mà họ khó có thể tìm thấy nếu không có sự trợ giúp.

Hệ thống gợi ý có thể chia thành 4 loại chính:



Hình 86: Bốn loại chính của hệ thống gợi ý

Tuy nhiên, trong khuôn khổ bài luận này, nhóm sẽ tập trung vào hệ thống gợi ý dựa trên nội dung (Content-based Recommenders). Hệ thống này hoạt động bằng cách sử dụng các đặc điểm của sản phẩm (ở đây là các bộ phim) để đề xuất những bộ phim tương tự. Chẳng hạn, nếu một bộ phim có các yếu tố như thể loại, đạo diễn, diễn viên, hoặc mô tả nội dung tương tự với bộ phim mà người dùng đang tìm kiếm, hệ thống sẽ gợi ý bộ phim đó.

Trong các hệ thống content-based, để đưa ra những đề xuất chính xác, chúng ta cần xây dựng một hồ sơ (profile) cho mỗi item (mỗi bộ phim). Hồ sơ này được biểu diễn dưới dạng một vector đặc trưng (feature vector) trong không gian n chiều. Do mỗi bộ phim được mô tả bởi một vector đặc trưng, và khi kết hợp tất cả các bộ phim lại, chúng ta sẽ có một ma trận kích thước $(m \times n)$, với m là số lượng bộ phim và n là chiều dài của vector đặc trưng. Để trích xuất những đặc trưng này từ dữ liệu dạng văn bản, nhóm sử dụng phương pháp TF-IDF (Term Frequency - Inverse Document Frequency). Và bằng cách tính toán độ tương đồng giữa các vector đặc trưng của các bộ phim, chúng ta có thể xác

định những bộ phim có nội dung tương đồng với nhau thông qua phương pháp Cosine Similarity.

2. Lý thuyết về Cosine Similarity

Cosine similarity là một phép đo thường được sử dụng để đo lường mức độ tương đồng giữa hai vector trong không gian vector. Thay vì đo khoảng cách giữa hai vector, cosine similarity đánh giá góc giữa chúng.

Công thức:

$$\text{Cosine similarity} = \frac{\vec{A} \cdot \vec{B}}{\|\vec{A}\| \times \|\vec{B}\|}$$

Trong đó:

- A và B là hai vector cần so sánh.
- $\vec{A} \cdot \vec{B}$ là tích vô hướng của hai vector.
- A và B là độ dài của hai vector.
- Độ dài của vector có n chiều được tính bằng: $A = \sqrt{\sum_{i=1}^n A_i^2}$
- Tích vô hướng của hai vector A và B có n chiều được tính bằng: $\vec{A} \cdot \vec{B} = \sum_{i=1}^n A_i B_i$

Ý nghĩa: Cosine similarity đo lường sự tương đồng theo hướng giữa hai vector, không xét đến độ lớn của chúng. Giá trị cosine similarity nằm trong khoảng [-1; 1].

- 1: hai vector hoàn toàn đồng hướng (giống nhau).
- 0: hai vector vuông góc (không liên quan).
- -1: hai vector ngược hướng (đối lập hoàn toàn).

Ưu điểm:

- Độc lập với độ lớn: Cosine similarity chỉ quan tâm đến hướng của vector, nên nó không bị ảnh hưởng bởi độ lớn của vector.
- Phù hợp trong xử lý ngôn ngữ tự nhiên (NLP) khi so sánh các tài liệu với nhau dựa trên vector từ hoặc TF-IDF.

3. Triển khai Recommend System trên Python

Tạo một dataframe mới và cập nhật index để phù hợp cho hệ thống đề xuất:

```
recommender_df = df1.copy()
recommender_df['show_id'] = recommender_df.index
```

Hình 87: Tạo dataframe để triển khai Hệ thống gợi ý

Xử lý dữ liệu, đưa các giá trị trong cột clustering_attributes từ dạng ['action', 'thriller',

'adventure'] thành kết quả là 'action thriller adventure', đồng thời cập nhật lại index của dataframe từ show_id thành title:

```
def convert(lst):
    return ' '.join(lst)

recommender_df['clustering_attributes'] = recommender_df['clustering_attributes'].apply(lambda x: convert(x))
recommender_df.set_index('title', inplace=True)
```

Hình 88: Cập nhật lại index của dataframe

Văn bản trong cột 'clustering_attributes' được chuyển đổi thành ma trận đếm từ khóa bằng phương pháp bag-of-words. Trong ma trận này, mỗi hàng tương ứng với một chương trình, còn mỗi cột biểu thị một từ khóa, với giá trị tại các ô là số lần từ khóa xuất hiện trong chương trình đó. Dựa trên ma trận từ khóa này, độ tương đồng cosin được tính toán giữa tất cả các cặp chương trình. Kết quả là một ma trận tương đồng, cung cấp cơ sở để xác định mức độ liên quan giữa các chương trình dựa trên thuộc tính phân cụm của chúng:

```
CV = CountVectorizer()
converted_matrix = CV.fit_transform(recommender_df['clustering_attributes'])
cosine_similarity = cosine_similarity(converted_matrix)
```

Hình 89: Tính độ tương đồng

Tạo một pandas series chứa các giá trị index của dataframe recommender_df để dễ dàng truy xuất chỉ số của một chương trình dựa trên tiêu đề. Sau đó, xây dựng hàm để gợi ý 10 chương trình tương tự dựa trên tiêu đề đầu vào. Bằng cách sử dụng ma trận độ tương đồng cosin, hàm sẽ tính toán mức độ liên quan giữa chương trình được chọn và các chương trình khác, sau đó trả về danh sách 10 chương trình phù hợp nhất. Trong trường hợp tiêu đề đầu vào không hợp lệ, hàm sẽ đưa ra thông báo lỗi:

```
indices = pd.Series(recommender_df.index)

def recommend_10(title, cosine_sim = cosine_similarity):
    try:
        recommend_content = []
        idx = indices[indices == title].index[0]
        series = pd.Series(cosine_sim[idx]).sort_values(ascending = False)
        top10 = list(series.iloc[1:11].index)
        # list with the titles of the best 10 matching movies
        for i in top10:
            recommend_content.append(list(recommender_df.index)[i])
        print("If you liked '"+title+"', you may also enjoy:\n")
        return recommend_content
    except:
        return 'Invalid Entry'
```

Hình 90: Code xử lý khi nhận được đầu vào

Tiến hành thực nghiệm sau khi đã xây dựng xong hệ thống gợi ý:

```
print(recommend_10('A Man Called God'), '\n\n\n')
print(recommend_10('Stranger Things'), '\n\n\n')
print(recommend_10('Peaky Blinders'), '\n\n\n')
print(recommend_10('Lucifer'), '\n\n\n')
recommend_10('XXX', '\n\n\n')
```

Hình 91: Thực nghiệm Hệ thống gợi ý

Tiến hành thực nghiệm sau khi đã xây dựng xong hệ thống gợi ý:

- Kết quả các bộ phim tương tự “Dick Johnson Is Dead”:

`recommend_10('Dick Johnson Is Dead')` 🚫

Các bộ phim tương tự 'Dick Johnson Is Dead', bạn có thể thích:

	title	listed_in	description
0	End Game	Documentaries	Facing an inevitable outcome, terminally ill p...
1	Moon	Dramas, Independent Movies, Sci-Fi & Fantasy	As he nears the end of a lonely three-year sti...
2	The Death and Life of Marsha P. Johnson	Documentaries, LGBTQ Movies	As she fights the tide of violence against tra...
3	Mac & Devin Go to High School	Comedies	Devin Overstreet may be the class valedictoria...
4	ReMastered: Devil at the Crossroads	Documentaries, Music & Musicals	Cloaked in mystery, bluesman Robert Johnson le...
5	A Gray State	Documentaries	This documentary dissects the case of a filma...
6	For the Win	Reality TV	Frisbee national champion Brodie Smith challen...
7	Secrets in the Hot Spring	Comedies, Horror Movies, International Movies	When three teen outcasts arrive at a hot sprin...
8	Kazoops!	Kids' TV	Music meets imagination in this inventive anim...
9	Black Snake Moan	Dramas, Independent Movies	Lazarus finds Rae beaten and near death, and a...

Hình 92: Kết quả các bộ phim tương tự “Dick Johnson Is Dead”

- Kết quả các bộ phim tương tự “Peaky Blinders”:

```
recommend_10('Peaky Blinders')
```

Các bộ phim tương tự 'Peaky Blinders', bạn có thể thích:

	title	listed_in	description
0	The Fear	British TV Shows, Crime TV Shows, TV Dramas	Richie Beckett is an aging Brighton crime boss...
1	Criminal: Spain	British TV Shows, Crime TV Shows, Internationa...	Psychological games abound between detectives ...
2	London Spy	British TV Shows, Crime TV Shows, Internationa...	When his reclusive-banker lover disappears, a ...
3	Criminal: UK	British TV Shows, Crime TV Shows, Internationa...	Within the walls of an interrogation room and ...
4	Paranoid	British TV Shows, Crime TV Shows, Internationa...	When a woman is brutally murdered on a playgro...
5	Spotless	Crime TV Shows, International TV Shows, TV Dramas	The law-abiding owner of a crime scene cleanin...
6	Jonathan Strange & Mr Norrell	British TV Shows, TV Dramas, TV Sci-Fi & Fantasy	In 1806, ambitious magician Norrell leads a re...
7	Kiss Me First	British TV Shows, Crime TV Shows, Internationa...	A lonely young woman hooked on a virtual reali...
8	Behind Her Eyes	British TV Shows, International TV Shows, TV D...	A single mother enters a world of twisted mind...
9	Marcella	British TV Shows, Crime TV Shows, Internationa...	Her marriage just ended and she's returning to...

Hình 93: Kết quả các bộ phim tương tự “Peaky Blinders”

- Nếu tên bộ phim không có trong bộ dữ liệu:

```
recommend_10('bbb')
```

```
'Show 'bbb' không có trong danh sách.'
```

Hình 94: Kết quả nếu bộ phim không tồn tại trong bộ dữ liệu

TÀI LIỆU THAM KHẢO

- Biswal, A. (2024, October 10). *What is Principal Component Analysis (PCA) in ML?* Simplilearn.com. <https://www.simplilearn.com/tutorials/machine-learning-tutorial/principal-component-analysis>
- Chen, K. (2022, January 6). Introduction to Natural Language Processing — TF-IDF. *Medium*. <https://kinder-chen.medium.com/introduction-to-natural-language-processing-tf-idf-1507e907c19>
- Hà, H. (2024, December 8). *Tìm hiểu về Content-based Filtering - Phương pháp gợi ý dựa theo nội dung (Phần 1)*. Viblo. <https://viblo.asia/p/tim-hieu-ve-content-based-filtering-phuong-phap-goi-y-dua-theo-noi-dung-phan-1-V3m5WGBg5O7>
- Huy, T. N. (2024, December 8). *ML From Scratch: Thuật toán giảm chiều dữ liệu PCA* - Viblo. Viblo. <https://viblo.asia/p/ml-from-scratch-thuat-toan-giam-chieu-du-lieu-pca-7ymJXKMa4kq>
- Jain, A. (2024, February 4). TF-IDF in NLP (Term Frequency Inverse Document Frequency). *Medium*. <https://medium.com/@abhishekjainindore24/tf-idf-in-nlp-term-frequency-inverse-document-frequency-e05b65932f1d>
- Vũ, T. (2017, January 1). *Bài 4: K-Means Clustering*. Tiep Vu's Blog. <https://machinelearningcoban.com/2017/01/01/kmeans/>
- What is a Recommendation System? (n.d.). NVIDIA Data Science Glossary. <https://www.nvidia.com/en-us/glossary/recommendation-system/#:~:text=A%20recommendation%20system%20is%20an,demographic%20information%2C%20and%20other%20factors.>
- What's the ASCII character code for “—”?* (n.d.). Stack Overflow. <https://stackoverflow.com/questions/10357622/whats-the-ascii-character-code-for#:~:text=%E2%80%94%20is%20known%20as%20an%20Em,It's%20character%20code%20is%20%5Cu2014%20>
- Wikipedia contributors. (2024, November 18). *Cosine similarity*. Wikipedia. https://en.wikipedia.org/wiki/Cosine_similarity